codigo4clases

Amelia Martínez Sequera

codigo4clases

Amelia Martínez Seguera

8/6/2021

2. Librerías

```
## Warning: package 'timevis' was built under R version 4.0.5
## Welcome! Want to learn more? See two factoextra-related books at
https://goo.gl/ve3WBa
##
## Attaching package: 'optCluster'
## The following objects are masked from 'package:clValid':
##
##
       clusterMethods, clusters, measNames, measures, nClusters,
       optimalScores
##
## Loading required package: Biobase
## Loading required package: BiocGenerics
## Loading required package: parallel
##
## Attaching package: 'BiocGenerics'
## The following objects are masked from 'package:parallel':
##
##
       clusterApply, clusterApplyLB, clusterCall, clusterEvalQ,
       clusterExport, clusterMap, parApply, parCapply, parLapply,
##
##
       parLapplyLB, parRapply, parSapplyLB
   The following objects are masked from 'package:stats':
##
##
       IQR, mad, sd, var, xtabs
##
   The following objects are masked from 'package:base':
##
##
##
       anyDuplicated, append, as.data.frame, basename, cbind, colnames,
##
       dirname, do.call, duplicated, eval, evalq, Filter, Find, get,
grep,
```

```
##
       grepl, intersect, is.unsorted, lapply, Map, mapply, match, mget,
##
       order, paste, pmax, pmax.int, pmin, pmin.int, Position, rank,
##
       rbind, Reduce, rownames, sapply, setdiff, sort, table, tapply,
##
       union, unique, unsplit, which.max, which.min
   Welcome to Bioconductor
##
##
##
       Vignettes contain introductory material; view with
       'browseVignettes()'. To cite Bioconductor, see
##
##
       'citation("Biobase")', and for packages 'citation("pkgname")'.
## Setting options('download.file.method.GEOquery'='auto')
## Setting options('GEOquery.inmemory.gpl'=FALSE)
##
## Attaching package: 'rlang'
##
   The following object is masked from 'package:Biobase':
##
##
       exprs
##
## Attaching package: 'limma'
   The following object is masked from 'package:BiocGenerics':
##
##
##
       plotMA
## Loading required package: amap
##
## Attaching package: 'dplyr'
## The following object is masked from 'package:Biobase':
##
##
       combine
   The following objects are masked from 'package:BiocGenerics':
##
##
       combine, intersect, setdiff, union
   The following object is masked from 'package:kableExtra':
##
##
##
       group_rows
   The following objects are masked from 'package:stats':
##
##
       filter, lag
##
## The following objects are masked from 'package:base':
##
       intersect, setdiff, setequal, union
##
```

```
## Loading required package: AnnotationDbi
## Loading required package: stats4
## Loading required package: IRanges
## Loading required package: S4Vectors
##
## Attaching package: 'S4Vectors'
   The following object is masked from 'package:tidyr':
##
##
       expand
   The following objects are masked from 'package:dplyr':
##
##
##
       first, rename
   The following object is masked from 'package:base':
##
##
##
       expand.grid
##
## Attaching package: 'IRanges'
## The following objects are masked from 'package:dplyr':
##
##
       collapse, desc, slice
##
   The following object is masked from 'package:grDevices':
##
##
       windows
##
## Attaching package: 'AnnotationDbi'
   The following object is masked from 'package:dplyr':
##
       select
##
## Loading required package: org.Hs.eg.db
##
##
## Welcome to beadarray version 2.40.0
##
## Attaching package: 'beadarray'
```

```
## The following object is masked from 'package:dplyr':
##
       summarize
##
   The following object is masked from 'package:limma':
##
##
##
       imageplot
##
   Loading required package: marray
##
## Attaching package: 'marray'
## The following object is masked from 'package:edgeR':
##
       maPlot
##
## Loading required package: GenomicRanges
## Loading required package: GenomeInfoDb
## Warning: package 'GenomeInfoDb' was built under R version 4.0.5
## Loading required package: SummarizedExperiment
## Loading required package: MatrixGenerics
## Loading required package: matrixStats
##
## Attaching package: 'matrixStats'
   The following objects are masked from 'package:genefilter':
##
##
       rowSds, rowVars
##
   The following object is masked from 'package:dplyr':
##
##
##
       count
   The following objects are masked from 'package:Biobase':
##
       anyMissing, rowMedians
##
##
## Attaching package: 'MatrixGenerics'
## The following objects are masked from 'package:matrixStats':
##
       colAlls, colAnyNAs, colAnys, colAvgsPerRowSet, colCollapse,
##
##
       colCounts, colCummaxs, colCummins, colCumprods, colCumsums,
##
       colDiffs, colIQRDiffs, colIQRs, colLogSumExps, colMadDiffs,
```

```
##
       colMads, colMaxs, colMeans2, colMedians, colMins, colOrderStats,
##
       colProds, colQuantiles, colRanges, colRanks, colSdDiffs, colSds,
##
       colSums2, colTabulates, colVarDiffs, colVars, colWeightedMads,
##
       colWeightedMeans, colWeightedMedians, colWeightedSds,
##
       colWeightedVars, rowAlls, rowAnyNAs, rowAnys, rowAvgsPerColSet,
##
       rowCollapse, rowCounts, rowCummaxs, rowCummins, rowCumprods,
##
       rowCumsums, rowDiffs, rowIQRDiffs, rowIQRs, rowLogSumExps,
##
       rowMadDiffs, rowMads, rowMaxs, rowMeans2, rowMedians, rowMins,
##
       rowOrderStats, rowProds, rowQuantiles, rowRanges, rowRanks,
       rowSdDiffs, rowSds, rowSums2, rowTabulates, rowVarDiffs, rowVars,
##
##
       rowWeightedMads, rowWeightedMeans, rowWeightedMedians,
##
       rowWeightedSds, rowWeightedVars
   The following objects are masked from 'package:genefilter':
##
##
       rowSds, rowVars
##
## The following object is masked from 'package:Biobase':
##
##
       rowMedians
##
## Attaching package: 'purrr'
## The following object is masked from 'package:GenomicRanges':
##
##
       reduce
## The following object is masked from 'package: IRanges':
##
##
       reduce
   The following objects are masked from 'package:rlang':
##
##
       %@%, as_function, flatten, flatten_chr, flatten_dbl, flatten_int,
##
       flatten_lgl, flatten_raw, invoke, list_along, modify, prepend,
##
       splice
## Warning: package 'caret' was built under R version 4.0.5
## Loading required package: lattice
##
## Attaching package: 'caret'
## The following object is masked from 'package:purrr':
##
##
       lift
3. Datos
gse<- "GSE136411"
gse_exprs <- getGEO(GEO=gse, GSEMatrix=TRUE)</pre>
```

3.1. Reestructuración de los datos

Se realizan una serie de modificaciones para almacenar la información en un dataframe en el que cada fila representa una muestra y las columnas contienen la información relativa a ellas (información descriptiva sobre el tipo de EM y la expresión de los genes).

```
str_replace_all('.*(PBMC_SP_).*','SP')%>%
str_replace_all('.*(PBMC_HC_).*','HC')%>%
str_replace_all('.*(PBMC_OND_).*','OND') -> datos$type

datos$characteristics_ch1 %>% as.factor()%>%
    str_replace_all('.*(disease: multiple sclerosis).*','MS')%>%
    str_replace_all('.*(disease: other neurological disease).*','Other')%>%
    str_replace_all('.*(disease: none).*','health') -> datos$grupo

info_muestras <-datos%>% dplyr::select(description, geo_accession, title, type, grupo)

datos<-datos%>% dplyr::select(-description, -title, -geo_accession, -characteristics_ch1, -type, -grupo)

datos<- log2(datos)

datos2<- cbind(info_muestras$description, datos)
names(datos2)[1] <- "muestra"</pre>
```

3.2. Filtrado de calidad de datos.

La tecnología microarray empleada para cuantificar los niveles de expresión tiene unos límites de detección, fuera de los cuales, la lectura no es fiable.

Si la señal es inferior a 10 unidades, se considera ruido y debe interpretarse como que no hay expresión de ese gen. En el extremo opuesto, 34 unidades es el valor máximo.

Prácticamente ninguno de los valores de este dataset se corresponden a lecturas por debajo del límite de detección (ruido), porque ya viene corregido.

Es importante remarcar que esta trasformación es un paso de limpieza, no un preprocesado de datos para mejorar el modelo, por lo tanto, sí puede hacerse sobre todas las observaciones antes de separarlas en conjunto de entrenamiento y test.

```
## [1] 0
```

3.4. Exploración de los datos.

3.4.1. Cantidad y tipo de muestras.

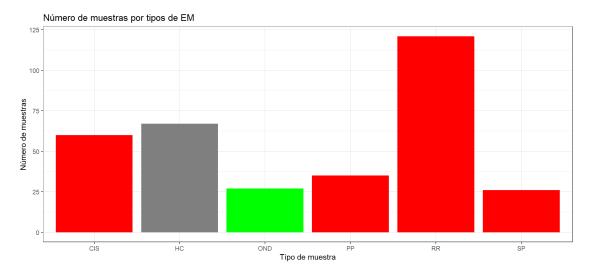
El set de datos se dispone de 336 muestras, agrupadas en 3 grupos, que a su vez se subdividen en tipos: sanos (HC), con EM (CIS,RR, PP, SP) y con otras enfermedades neurológicas (OND).

```
info_muestras %>%
  dplyr::group_by(grupo) %>%
  dplyr::count()

info_muestras %>%
  dplyr::filter(grupo == "MS") %>%
  dplyr::group_by(type) %>%
  dplyr::count()

info_muestras %>%
  dplyr::group_by(type) %>%
  dplyr::group_by(type) %>%
  dplyr::count() %>%
  ggplot(aes(x = reorder(type, n), y = n)) +
    geom_col(fill = "gray60", color = "black") +
    coord_flip() +
    theme_bw() +
```

Número de muestras por tipo RR HC OND PP OND SP Número de muestras



3.4.2. Valores ausentes.

```
na_por_columna \leftarrow map_dbl(.x = datos, .f = function(x){sum(is.na(x))}) any(na por columna > 0)
```

```
## [1] FALSE
```

Se comprueba que para todas las muestras se dispone del valor de expresión .El set de datos está completo, no hay valores ausentes.

4. División y preprocesado de los datos.

```
4.1. División de los datos.
datost <- cbind(info_muestras$type, datos)</pre>
names(datost)[1] <- "type"</pre>
datost <- datost %>% dplyr::filter(type== c("CIS", "PP","SP","RR"))
# Se crean los índices de las observaciones de entrenamiento (80%)
set.seed(123)
train <- createDataPartition(y = datost$type, p = 0.8, list = FALSE,
times = 1)
datos_train <- datost[train, ]</pre>
datos_test <- datost[-train, ]</pre>
Es importante verificar que la distribución de la variable respuesta es similar en el
conjunto de entrenamiento y en el de test. Por defecto, la función
createDataPartition() garantiza una distribución aproximada (reparto estratificado).
distribucion train <- prop.table(table(datos train$type)) %>% round(3)
distribucion test <- prop.table(table(datos test$type)) %>% round(3)
data.frame(train = distribucion_train, test = distribucion_test )
Aciertos si se emplea la clase mayoritaria como predictor:
# Aciertos si se emplea la clase mayoritaria como predictor
mean(datos train$type == "RR")
## [1] 0.4897959
4.2. Preprocesado.
4.2.1. Genes con varianza próxima a cero.
sum(datos_train%>% nearZeroVar(saveMetrics = TRUE) == FALSE)
```

5. Selección de genes y reducción de dimensionalidad:

estandarizador <- preProcess(x = datos_train, method = c("center",</pre>

Anova p-value

4.2.2. Estandarización.

[1] 20322

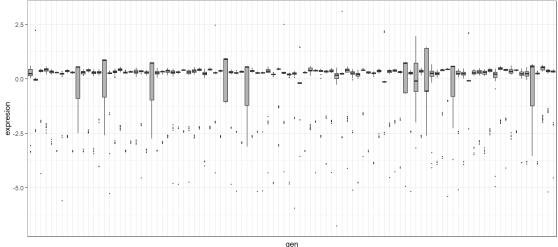
"scale"))

Signal to noise (S2N)

- Comparación de filtrados
- Reducción de dimensionalidad

5.1. Anova p-value

```
# Representación de la expresión de 100 genes seleccionados de forma
aleatoria.
set.seed(123)
datos_train %>% select_at(sample(4:ncol(datos_train), 100)) %>%
  gather(key = "gen", value = "expresion") %>%
  ggplot(aes(x = gen , y = expresion)) +
    geom_boxplot(outlier.size = 0.3, fill = "gray70") +
    theme_bw() +
    theme(axis.text.x = element_blank(),
        axis.ticks.x = element_blank())
```



Se aplica un análisis ANOVA para cada uno de los genes.

.

VERSIÓN NO PARALELIZADA

```
# Se emplea un número de resampling bajo para que no tarde demasiado.

Para valores más elevados emplear la versión paralelizada que se describe más adelante.

n hoot <- 3
```

```
n boot <- 3
resultados_anova <- vector(mode = "list", length = n_boot)</pre>
# Semillas para que los muestreos sean reproducibles
set.seed(123)
seeds = sample.int(1000, size = n_boot)
# Función ANOVA
custom_anova <- function(x,y){</pre>
  anova <- summary(aov(x \sim as.factor(y)))
  return(unlist(anova)["Pr(>F)1"])
}
for (i in 1:n_boot){
  # Se crea una muestra bootstrapping
  set.seed(seeds[i])
  indices <- sample(1:nrow(datos_train), size = nrow(datos_train),</pre>
replace = TRUE)
  pseudo_muestra <- datos_train[indices, ]</pre>
   # Se calculan los p-values con la nueva muestra
  resultados_anova[[i]] <- pseudo_muestra %>%
                            dplyr::select(-type) %>%
                            map dbl(.f = custom anova, y =
pseudo_muestra$type)
# Los resultados almacenados en forma de lista se convierten en dataframe
names(resultados anova) <- paste("resample", 1:n boot, sep = " ")</pre>
resultados_anova <- data.frame(resultados_anova)</pre>
resultados_anova<- cbind(rownames(resultados_anova),</pre>
data.frame(resultados_anova, row.names = NULL))
names(resultados_anova)[1] = "gen"
resultados_anova <- resultados_anova %>%
                       mutate(pvalue_medio = rowMeans(resultados_anova[, -
1])) %>%
                       arrange(pvalue_medio)
head(resultados anova)
```

Los resultados almacenados en forma de lista se convierten en dataframe.

Para agilizar el proceso, es recomendable paralelizar el loop externo.

```
VERSIÓN PARALELIZADA DE BOOTSTRAPPING PARA FILTRADO POR ANOVA
library(doParallel)
# Se especifica el número de cores a utilizar (esto depende del ordenador
empleado)
registerDoParallel(cores = 3)
getDoParWorkers()
## [1] 3
# Número de iteraciones bootstrapping
n boot <- 100
# Semillas para que los muestreos sean reproducibles
set.seed(123)
seeds = sample.int(1000, size = n_boot)
# Función ANOVA
custom anova <- function(x,y){</pre>
  anova <- summary(aov(x \sim as.factor(y)))
  return(unlist(anova)["Pr(>F)1"])
}
### LOOP PARALELIZADO
library(parallel)
# La función foreach devuelve los resultados de cada iteración en una
Lista
resultados anova pvalue <- foreach(i = 1:n boot) %dopar% {
  require(dplyr)
  require(purrr)
  # Se crea una muestra por bootstrapping
  set.seed(seeds[i])
  indices <- sample(1:nrow(datos train), size = nrow(datos train),</pre>
replace = TRUE)
  pseudo_muestra <- datos_train[indices, ]</pre>
  # Se calculan los p-values para la nueva muestra
  p values <- pseudo muestra %>%
    select(-type) %>%
    map dbl(.f = custom anova, y = pseudo muestra$type)
  # Se devuelven los p-value
```

```
p_values
options(cores = 1)
require(dplyr)
require(tidyverse)
## Error in completeSubclasses(classDef2, class1, obj, where) :
     tentativa de obtener un slot "subclasses" de un objeto de una clase
básica ("NULL") sin slots
# Los resultados almacenados en forma de lista se convierten en dataframe
names(resultados anova pvalue) <- paste("resample", 1:n boot, sep = " ")</pre>
resultados_anova_pvalue <- data.frame(resultados_anova_pvalue)</pre>
resultados_anova_pvalue <- resultados_anova_pvalue %>%
tibble::rownames to column(var = "gen")
resultados anova pvalue <- resultados anova pvalue %>%
mutate(pvalue medio = rowMeans(resultados anova pvalue[, -1])) %>%
  arrange(pvalue_medio)
# Se quarda en disco el objeto creado para no tener que repetir de nuevo
toda la computación.
saveRDS(object = resultados_anova_pvalue, file =
"resultados anova pvalue.rds")
head(resultados_anova_pvalue)
Se guarda en disco el objeto creado para no tener que repetir de nuevo toda la
computación: "resultados anova pvalue.rds"
resultados_anova_pvalue %>% dplyr::select(1,2,3,4) %>% head()
Anotación de los genes.
ann<- select(illuminaHumanv3.db, keys = resultados_anova_pvalue$gen,</pre>
columns=c("ENTREZID", "SYMBOL", "GENENAME"))
ann[1:25,]
# Se filtran los 100, 50 y 25 genes identificados como más relevantes
mediante anova
filtrado_anova_pvalue_100 <- resultados_anova_pvalue %>% pull(gen) %>%
head(100)
filtrado_anova_pvalue_50 <- resultados_anova_pvalue %>% pull(gen) %>%
filtrado anova pvalue 25 <- resultados anova pvalue %>% pull(gen) %>%
head(25)
```

```
5.2. Signal to noise (S2N)
S2N=\{\frac{\mu_{grupo i} - \mu_{resto de grupos}}{\sigma_{grupo i} + \sigma_{resto de grupos}}\}
# Se identifica el nombre de los distintos grupos (tipos de tumor)
grupos <- unique(datos train$type)</pre>
# Se crea una lista donde almacenar los resultados para cada grupo
s2n por grupo <- vector(mode = "list", length = length(grupos))</pre>
names(s2n por grupo) <- grupos</pre>
# Se calcula el valor S2N de cada gen en cada grupo
for (grupo in grupos){
  # Media y desviación de cada gen en el grupo i
  datos_grupo <- datos_train %>% filter(type == grupo) %>%
dplyr::select(-type)
  medias_grupo <- map_dbl(datos_grupo, .f = mean)</pre>
  sd grupo <- map dbl(datos grupo, .f = sd)</pre>
  # Media y desviación de cada gen en el resto de grupos
  datos_otros <- datos_train %>% filter(type != grupo) %>%
dplyr::select(-type)
  medias_otros <- map_dbl(datos_otros, .f = mean)</pre>
  sd otros <- map dbl(datos otros, .f = sd)</pre>
  # Calculo S2N
  s2n <- (medias_grupo - medias_otros)/(sd_grupo + sd_otros)</pre>
  s2n_por_grupo[[grupo]] <- s2n</pre>
}
extraer_top_genes <- function(x, n=10, abs=TRUE){</pre>
  if (abs == TRUE) {
  x \leftarrow abs(x)
  x \leftarrow sort(x)
  x \leftarrow x[1:n]
  return(names(x))
  }else{
  x \leftarrow sort(x)
  x \leftarrow x[1:n]
  return(names(x))
  }
}
s2n_por_grupo <- s2n_por_grupo %>% map(.f = extraer_top_genes)
genes seleccionados s2n <- unique(unlist(s2n por grupo))</pre>
length(genes seleccionados s2n)
## [1] 40
```

```
annotation<- select(illuminaHumanv3.db, keys = genes_seleccionados_s2n,
columns=c("ENTREZID","SYMBOL","GENENAME"))
annotation[1:25,]</pre>
```

Al igual, que en el filtrado por ANOVA, para evitar que la selección este excesivamente influenciada por la muestra de entrenamiento, es conveniente recurrir a un proceso de resampling y agregar los resultados. Esta vez, como método de agregación se emplea la media.

VERSIÓN PARALELIZADA DE BOOTSTRAPPING PARA FILTRADO POR SIGNAL TO NOISE # Warning: Este cálculo puede tardar varias horas.

```
library(doParallel)
# Se especifica el número de cores a utilizar (esto depende del
ordenador)
registerDoParallel(cores = 3)
# Número de iteraciones bootstrapping
n boot <- 100
# Semillas para que los muestreos sean reproducibles
set.seed(123)
seeds = sample.int(1000, size = n boot)
# LOOP PARALELIZADO
resultados_s2n <- foreach(i = 1:n_boot) %dopar% {</pre>
  require(purrr)
  require(dplyr)
  # Se crea una nueva muestra por bootstrapping
  set.seed(seeds[i])
  indices <- sample(1:nrow(datos train),</pre>
                     size = nrow(datos train),
                     replace = TRUE)
  pseudo_muestra <- datos_train[indices, ]</pre>
  # Se identifica el nombre de los distintos grupos (tipos de tumor)
  grupos <- unique(pseudo_muestra$type)</pre>
  # Se crea una lista donde almacenar los resultados para cada grupo
  s2n_por_grupo <- vector(mode = "list", length = length(grupos))</pre>
  names(s2n por grupo) <- grupos</pre>
  # Se calcula el valor S2N de cada gen en cada grupo
  for (grupo in grupos){
    # Media y desviación de cada gen en el grupo i
    datos grupo <- pseudo muestra %>% filter(type == grupo) %>% select(-
```

```
type)
    medias_grupo <- map_dbl(datos_grupo, .f = mean)</pre>
                <- map dbl(datos grupo, .f = sd)</pre>
    # Media y desviación de cada gen en el resto de grupos
    datos_otros <- pseudo_muestra %>% filter(type != grupo) %>% select(-
type)
    medias_otros <- map_dbl(datos_otros, .f = mean)</pre>
                <- map_dbl(datos_otros, .f = sd)</pre>
    # Calculo S2N
    s2n <- (medias_grupo - medias_otros)/(sd_grupo + sd_otros)</pre>
    s2n_por_grupo[[grupo]] <- s2n</pre>
  s2n_por_grupo
options(cores = 1)
names(resultados_s2n) <- paste("resample", 1:n_boot, sep = "_")</pre>
# Se quarda en disco el objeto creado
saveRDS(object = resultados s2n, file = "resultados s2n.rds")
En cada elemento de la lista resultados_s2n se ha almacenado el resultado de una
repetición bootstrapping, que a su vez, es otra lista con los valores S2N de cada gen en
cada grupo. Para obtener un único listado final por tipo, se tienen que agregar los
valores obtenidos en las diferentes repeticiones.
require(tidyverse)
## Error in completeSubclasses(classDef2, class1, obj, where) :
     tentativa de obtener un slot "subclasses" de un objeto de una clase
básica ("NULL") sin slots
require(dplyr)
resultados s2n grouped <- resultados s2n %>%
  unlist() %>%
  as.data.frame() %>%
  tibble:: rownames_to_column(var = "id") %>%
  separate(col = id, sep = "[.]",
           remove = TRUE.
           into = c("resample", "type", "gen")) %>%
  dplyr::rename(s2n =".") %>%
  group_by(type) %>%
  nest()
# Para cada tipo se calcula el s2n medio de los genes y se devuelven los
10 genes con mayor S2N absoluto
```

```
extraer top genes <- function(df, n=10){
  df <- df %>% spread(key = "resample", value = s2n)
  df <- df %>% mutate(s2n medio = abs(rowMeans(df[, -1])))
  top genes <- df %>% arrange(desc(s2n medio)) %>% pull(gen) %>% head(n)
  return(as.character(top_genes))
}
resultados s2n grouped <- resultados s2n grouped %>%
  mutate(gen = map(.x = data, .f = extraer top genes))
resultados s2n grouped %>%
  head()
saveRDS(object = resultados s2n grouped, file =
"resultados s2n grouped.rds")
Para cada tipo se calcula el s2n medio de los genes y se devuelven los 10 genes con
mayor S2N absoluto: "resultados s2n grouped.rds"
se identifica la intersección entre los genes seleccionados para cada tipo, y se
eliminan aquellos que son comunes para varios estadíos (aparecen más de dos veces):
"filtrado s2n 60.rds"
genes repetidos <- resultados s2n grouped %>%
                     pull(gen) %>%
                     unlist() %>%
                     table() %>%
                     as.data.frame() %>%
                     filter(Freq > 1) %>%
                     pull(".") %>%
                     as.character()
filtrado s2n 60 <- resultados s2n grouped %>%
                     pull(gen) %>%
                     unlist()
filtrado_s2n_60 <- filtrado_s2n_60[!(filtrado_s2n_60 %in%
genes repetidos)]
saveRDS(object = filtrado s2n 60, file = "filtrado s2n 60.rds")
El mismo proceso se repite pero seleccionando únicamente los top 5 genes por
grupo: "filtrado_s2n_30.rds"
extraer_top_genes <- function(df, n=5){</pre>
  df <- df %>% spread(key = "resample", value = s2n)
  df <- df %>% mutate(s2n medio = abs(rowMeans(df[, -1])))
  top_genes <- df %>% arrange(desc(s2n_medio)) %>% pull(gen) %>% head(n)
  return(as.character(top genes))
```

```
resultados s2n grouped <- resultados s2n grouped %>%
  mutate(gen = map(.x = data, .f = extraer_top_genes))
resultados_s2n_grouped %>%
  head()
saveRDS(object = resultados s2n grouped, file =
"resultados_s2n_grouped.rds")
genes repetidos <- resultados_s2n_grouped %>%
                    pull(gen) %>%
                    unlist() %>%
                    table() %>%
                    as.data.frame() %>%
                    filter(Freq > 1) %>%
                    pull(".") %>%
                    as.character()
filtrado_s2n_30 <- resultados_s2n_grouped %>%
                    pull(gen) %>%
                    unlist()
filtrado_s2n_30 <- filtrado_s2n_30[!(filtrado_s2n_30 %in%
genes repetidos)]
saveRDS(object = filtrado s2n 30, file = "filtrado s2n 30.rds")
```

5.3. Comparación de filtrados

Se estudia cuantos genes en común se han seleccionado con cada uno de los métodos.

```
length(intersect(filtrado_anova_pvalue_100, filtrado_s2n_60))
## [1] 16
length(intersect(filtrado_anova_pvalue_50, filtrado_s2n_30))
## [1] 7
```

La selección de genes resultante con ambos métodos es muy distinta.

5.4. Reducción de dimensionalidad

Se aplica un PCA a los niveles de expresión y se conservan las componentes principales hasta alcanzar un 95% de varianza explicada.

```
transformacion_pca <- preProcess(x = datos_train, method = "pca", thresh
= 0.95)
transformacion_pca
## Created from 49 samples and 10161 variables
##</pre>
```

6. Modelos:

- SVM
- RandomForest
- Neural Network

6.1. SVM: Máquinas de Vector Soporte (Support Vector Machines, SVMs)

El método symRadial de caret emplea la función ksym() del paquete kernlab. Este algoritmo tiene 2 hiperparámetros:

- sigma: coeficiente del kernel radial.
- C: penalización por violaciones del margen del hiperplano.

```
6.1.1. Filtrado por ANOVA p-value 100
# PARALELIZACIÓN DE PROCESO
library(doParallel)
registerDoParallel(cores = 3)
# HIPERPARÁMETROS, NÚMERO DE REPETICIONES Y SEMILLAS PARA CADA REPETICIÓN
repeticiones boot <- 50
# Hiperparámetros
hiperparametros \leftarrow expand.grid(sigma = c(0.0001, 0.001, 0.01),
                                 C = c(1, 10, 50, 100, 250, 500, 700,
1000))
set.seed(123)
seeds <- vector(mode = "list", length = repeticiones_boot + 1)</pre>
for (i in 1:repeticiones boot) {
  seeds[[i]] <- sample.int(1000, nrow(hiperparametros))</pre>
seeds[[repeticiones_boot + 1]] <- sample.int(1000, 1)</pre>
# DEFINICIÓN DEL ENTRENAMIENTO
control train <- trainControl(method = "boot", number =</pre>
repeticiones_boot,
                               seeds = seeds, returnResamp = "final",
```

```
verboseIter = FALSE, allowParallel = TRUE)
# AJUSTE DEL MODELO
set.seed(342)
svmrad pvalue 100 <- train(</pre>
                      form = type ~ .,
                      data = datos_train[c("type",
filtrado anova pvalue 100)],
                     method = "svmRadial",
                     tuneGrid = hiperparametros,
                     metric = "Accuracy",
                      trControl = control train
                    )
registerDoParallel(cores = 1)
saveRDS(object = svmrad pvalue 100, file = "svmrad pvalue 100.rds")
svmrad_pvalue_100
## Support Vector Machines with Radial Basis Function Kernel
##
## 49 samples
## 100 predictors
    4 classes: 'CIS', 'PP', 'RR', 'SP'
##
##
## No pre-processing
## Resampling: Bootstrapped (50 reps)
## Summary of sample sizes: 49, 49, 49, 49, 49, ...
## Resampling results across tuning parameters:
##
##
     sigma C
                 Accuracy
                            Kappa
##
    1e-04
              1 0.4791786
                            0.01329193
##
    1e-04
             10 0.7125241
                            0.51300862
##
    1e-04
             50 0.8948747 0.83663585
##
    1e-04
            100 0.8950512 0.83718797
##
    1e-04
             250 0.8938747
                            0.83537956
##
    1e-04
             500 0.8938747
                            0.83537956
##
    1e-04
             700 0.8938747
                            0.83537956
##
     1e-04 1000 0.8938747
                            0.83537956
##
     1e-03
              1 0.6437233 0.39844722
##
    1e-03
             10 0.8873258 0.82974473
##
    1e-03
             50 0.8873258 0.82923811
##
    1e-03
             100 0.8873258 0.82923811
##
    1e-03
             250 0.8873258 0.82923811
    1e-03
##
             500 0.8873258
                            0.82923811
##
    1e-03
           700 0.8873258
                            0.82923811
     1e-03 1000 0.8873258 0.82923811
##
##
     1e-02
             1 0.7911679 0.68263479
##
    1e-02
             10 0.7977563 0.69416438
##
    1e-02
             50 0.7977563 0.69416438
##
    1e-02
             100 0.7977563 0.69416438
##
     1e-02
             250 0.7977563 0.69416438
```

```
1e-02
              500 0.7977563 0.69416438
##
##
     1e-02
              700 0.7977563 0.69416438
##
     1e-02 1000 0.7977563 0.69416438
##
## Accuracy was used to select the optimal model using the largest value.
## The final values used for the model were sigma = 1e-04 and C = 100.
ggplot(svmrad_pvalue_100, highlight = TRUE) +
  labs(title = "Evolución del accuracy del modelo SVM Radial") +
  theme_bw()
   Evolución del accuracy del modelo SVM Radial
 0.8
(Bootstrap)
                                                                       Sigma
                                                                       1e-03
Accuracy
                                                                       -- 1e-04
 0.6
 0.5
                                   500
Cost
6.1.2. Filtrado por ANOVA p-value 50
# PARALELIZACIÓN DE PROCESO
registerDoParallel(cores = 3)
# HIPERPARÁMETROS, NÚMERO DE REPETICIONES Y SEMILLAS PARA CADA REPETICIÓN
repeticiones boot <- 50
# Hiperparámetros
hiperparametros \leftarrow expand.grid(sigma = c(0.0001, 0.001, 0.01),
                                  C = c(1, 10, 50, 100, 500, 700, 1000,
1500))
set.seed(123)
seeds <- vector(mode = "list", length = repeticiones_boot + 1)</pre>
for (i in 1:repeticiones boot) {
  seeds[[i]] <- sample.int(1000, nrow(hiperparametros))</pre>
}
seeds[[repeticiones_boot + 1]] <- sample.int(1000, 1)</pre>
# DEFINICIÓN DEL ENTRENAMIENTO
control_train <- trainControl(method = "boot", number =</pre>
repeticiones boot,
                                 seeds = seeds, returnResamp = "final",
```

```
# AJUSTE DEL MODELO
set.seed(342)
svmrad_pvalue_50 <- train(</pre>
                      form = type ~ .,
                      data = datos_train[c("type",
filtrado_anova_pvalue_50)],
                      method = "svmRadial",
                     tuneGrid = hiperparametros,
                     metric = "Accuracy",
                     trControl = control train
                    )
registerDoParallel(cores = 1)
saveRDS(object = svmrad_pvalue_50, file = "svmrad_pvalue_50.rds")
svmrad pvalue 50
## Support Vector Machines with Radial Basis Function Kernel
##
## 49 samples
## 50 predictors
## 4 classes: 'CIS', 'PP', 'RR', 'SP'
##
## No pre-processing
## Resampling: Bootstrapped (50 reps)
## Summary of sample sizes: 49, 49, 49, 49, 49, ...
## Resampling results across tuning parameters:
##
##
    sigma C
                  Accuracy
                             Kappa
##
     1e-04
               1 0.4791786
                            0.01329193
##
     1e-04
              10 0.5021160 0.07645399
##
     1e-04
              50 0.8623623
                            0.77153603
##
    1e-04
             100 0.8748250
                            0.79363558
##
    1e-04
             500 0.8819139
                            0.80780597
##
    1e-04
            700 0.8819139
                            0.80780597
##
    1e-04 1000 0.8819139 0.80780597
##
    1e-04 1500 0.8819139
                            0.80780597
##
    1e-03
                 0.4957089
              1
                            0.06386795
##
     1e-03
              10 0.8761419
                            0.80099625
##
     1e-03
              50 0.8787958
                            0.80724572
##
     1e-03
             100 0.8787958
                            0.80724572
##
    1e-03
             500 0.8787958 0.80724572
##
     1e-03
             700 0.8787958
                            0.80724572
##
     1e-03 1000 0.8787958 0.80724572
    1e-03 1500 0.8787958 0.80724572
##
              1 0.8391626
##
    1e-02
                            0.74789133
##
    1e-02
              10 0.8535151 0.77103453
##
     1e-02
              50 0.8535151 0.77103453
##
     1e-02
             100 0.8535151 0.77103453
```

```
1e-02
                   0.8535151 0.77103453
##
              500
##
     1e-02
              700 0.8535151 0.77103453
##
     1e-02 1000 0.8535151 0.77103453
##
     1e-02 1500 0.8535151
                               0.77103453
##
## Accuracy was used to select the optimal model using the largest value.
## The final values used for the model were sigma = 1e-04 and C = 500.
ggplot(symrad pvalue 50, highlight = TRUE) +
  labs(title = "Evolución del accuracy del modelo SVM Radial") +
  theme_bw()
   Evolución del accuracy del modelo SVM Radial
Accuracy (Bootstrap)
                                                                       → 1e-02
                                                                       - 1e-04
 0.5
                                   Cost
6.1.3. Filtrado por ANOVA p-value 25
# PARALELIZACIÓN DE PROCESO
registerDoParallel(cores = 3)
# HIPERPARÁMETROS, NÚMERO DE REPETICIONES Y SEMILLAS PARA CADA REPETICIÓN
repeticiones_boot <- 50
# Hiperparámetros
hiperparametros \leftarrow expand.grid(sigma = c(0.0001, 0.001, 0.01),
                                  C = c(1, 10, 50, 100, 500, 700, 1000,
1500))
set.seed(123)
seeds <- vector(mode = "list", length = repeticiones_boot + 1)</pre>
for (i in 1:repeticiones_boot) {
  seeds[[i]] <- sample.int(1000, nrow(hiperparametros))</pre>
}
seeds[[repeticiones_boot + 1]] <- sample.int(1000, 1)</pre>
# DEFINICIÓN DEL ENTRENAMIENTO
```

```
control_train <- trainControl(method = "boot", number =</pre>
repeticiones_boot,
                             seeds = seeds, returnResamp = "final",
                             verboseIter = FALSE, allowParallel = TRUE)
# AJUSTE DEL MODELO
set.seed(342)
svmrad pvalue 25 <- train(</pre>
                     form = type ~ .,
                     data = datos_train[c("type",
filtrado_anova_pvalue_25)],
                     method = "svmRadial",
                     tuneGrid = hiperparametros,
                     metric = "Accuracy",
                     trControl = control train
                    )
registerDoParallel(cores = 1)
saveRDS(object = svmrad_pvalue_25, file = "svmrad_pvalue_25.rds")
svmrad_pvalue_25
## Support Vector Machines with Radial Basis Function Kernel
##
## 49 samples
## 25 predictors
## 4 classes: 'CIS', 'PP', 'RR', 'SP'
##
## No pre-processing
## Resampling: Bootstrapped (50 reps)
## Summary of sample sizes: 49, 49, 49, 49, 49, ...
## Resampling results across tuning parameters:
##
##
    sigma C
                 Accuracy
                            Kappa
##
    1e-04
              1 0.4791786 0.01357143
##
    1e-04
             10 0.4791786 0.01357143
           50 0.7892523 0.63535263
##
    1e-04
##
    1e-04 100 0.8505650 0.74779394
##
    1e-04
            500 0.8257308 0.71172037
##
    1e-04
           700 0.8220904 0.70666939
    1e-04 1000 0.8089549 0.68633023
##
    1e-04 1500 0.8005975 0.67210640
##
##
    1e-03
             1 0.4791786 0.01357143
##
    1e-03
             10 0.8481841 0.74491587
##
    1e-03
             50 0.8251649 0.71220236
##
    1e-03
           100 0.8072501 0.68481045
##
    1e-03
            500 0.7853111 0.65073789
##
    1e-03 700 0.7853111 0.65073789
##
    1e-03 1000 0.7853111 0.65073789
##
    1e-03 1500 0.7853111 0.65073789
```

```
1e-02
               1 0.8284625 0.72024107
##
##
     1e-02
               10 0.8120096 0.70006383
     1e-02
               50 0.7887026 0.66521928
##
##
     1e-02
              100 0.7887026
                               0.66521928
##
     1e-02
              500 0.7887026
                               0.66521928
##
     1e-02
              700 0.7887026
                               0.66521928
##
     1e-02 1000 0.7887026
                               0.66521928
##
     1e-02 1500 0.7887026 0.66521928
##
## Accuracy was used to select the optimal model using the largest value.
## The final values used for the model were sigma = 1e-04 and C = 100.
ggplot(svmrad_pvalue_25, highlight = TRUE) +
  labs(title = "Evolución del accuracy del modelo SVM Radial") +
  theme bw()
   Evolución del accuracy del modelo SVM Radial
 0.8
Accuracy (Bootstrap)
                                                                      Sigma
                                                                      → 1e-02
                                                                      → 1e-03
                                                                      1e-04
 0.5
                                             1000
                                   Cost
6.1.4. Filtrado por S2N 60
# PARALELIZACIÓN DE PROCESO
registerDoParallel(cores = 3)
# HIPERPARÁMETROS, NÚMERO DE REPETICIONES Y SEMILLAS PARA CADA REPETICIÓN
repeticiones boot <- 50
# Hiperparámetros
hiperparametros \leftarrow expand.grid(sigma = c(0.0001, 0.001, 0.01),
                                 C = c(10, 50, 100, 200, 600, 800, 1000,
1500))
set.seed(123)
seeds <- vector(mode = "list", length = repeticiones_boot + 1)</pre>
for (i in 1:repeticiones boot) {
  seeds[[i]] <- sample.int(1000, nrow(hiperparametros))</pre>
}
seeds[[repeticiones boot + 1]] <- sample.int(1000, 1)</pre>
```

DEFINICIÓN DEL ENTRENAMIENTO

```
control_train <- trainControl(method = "boot", number =</pre>
repeticiones boot,
                              seeds = seeds, returnResamp = "final",
                              verboseIter = FALSE, allowParallel = TRUE)
# AJUSTE DEL MODELO
set.seed(342)
svmrad s2n 60 <- train(</pre>
                      form = type ~ .,
                      data = datos_train[c("type", filtrado_s2n_60)],
                      method = "svmRadial",
                      tuneGrid = hiperparametros,
                      metric = "Accuracy",
                      trControl = control train
                      )
registerDoParallel(cores = 1)
saveRDS(object = svmrad_s2n_60, file = "svmrad_s2n_60.rds")
svmrad s2n 60
## Support Vector Machines with Radial Basis Function Kernel
##
## 49 samples
## 20 predictors
## 4 classes: 'CIS', 'PP', 'RR', 'SP'
##
## No pre-processing
## Resampling: Bootstrapped (50 reps)
## Summary of sample sizes: 49, 49, 49, 49, 49, ...
## Resampling results across tuning parameters:
##
##
     sigma C
                  Accuracy
                             Kappa
##
    1e-04
             10 0.4864917 0.03076805
##
    1e-04
              50 0.7091570 0.48233046
##
    1e-04
           100 0.7257777 0.53176088
##
    1e-04
             200 0.7126450 0.52662072
##
    1e-04
             600 0.6795512 0.49902179
##
    1e-04
            800 0.6716300 0.49519440
##
    1e-04 1000 0.6654850 0.49129428
##
    1e-04 1500 0.6560171 0.48037477
##
    1e-03
             10 0.7257777 0.53167200
##
    1e-03
              50 0.6864158 0.50676533
##
    1e-03
           100 0.6654850 0.49031464
##
    1e-03
             200 0.6512483 0.47725611
##
    1e-03
             600 0.6494919 0.47626209
##
    1e-03
             800 0.6507419 0.47797112
    1e-03 1000 0.6507419 0.47797112
##
```

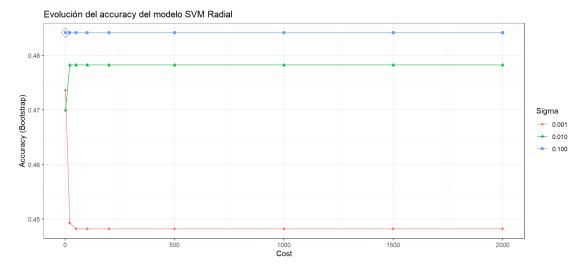
```
1e-03 1500 0.6517946 0.48003461
##
##
     1e-02
               10 0.6786010 0.50609606
     1e-02
##
               50 0.6636528 0.49192368
##
     1e-02
              100 0.6636528
                               0.49192368
##
     1e-02
              200 0.6636528
                               0.49192368
##
     1e-02
              600
                   0.6636528
                               0.49192368
##
     1e-02
              800 0.6636528
                               0.49192368
##
     1e-02 1000 0.6636528 0.49192368
##
     1e-02 1500 0.6636528 0.49192368
##
## Accuracy was used to select the optimal model using the largest value.
## The final values used for the model were sigma = 0.001 and C = 10.
ggplot(svmrad s2n 60, highlight = TRUE) +
  labs(title = "Evolución del accuracy del modelo SVM Radial") +
  theme_bw()
   Evolución del accuracy del modelo SVM Radial
(Bootstrap)
                                                                     Sigma
Accuracy (I
                                                                      → 1e-03
 0.50
                                            1000
                                  Cost
6.1.5. Filtrado por S2N 30
# PARALELIZACIÓN DE PROCESO
registerDoParallel(cores = 3)
# HIPERPARÁMETROS, NÚMERO DE REPETICIONES Y SEMILLAS PARA CADA REPETICIÓN
repeticiones boot <- 50
# Hiperparámetros
hiperparametros \leftarrow expand.grid(sigma = c(0.0001, 0.001, 0.01),
                                 C = c(10, 50, 100, 200, 600, 800, 1000,
1500))
set.seed(123)
seeds <- vector(mode = "list", length = repeticiones_boot + 1)</pre>
for (i in 1:repeticiones boot) {
  seeds[[i]] <- sample.int(1000, nrow(hiperparametros))</pre>
}
```

```
seeds[[repeticiones_boot + 1]] <- sample.int(1000, 1)</pre>
# DEFINICIÓN DEL ENTRENAMIENTO
control_train <- trainControl(method = "boot", number =</pre>
repeticiones boot,
                              seeds = seeds, returnResamp = "final",
                              verboseIter = FALSE, allowParallel = TRUE)
# AJUSTE DEL MODELO
set.seed(342)
svmrad s2n_30 <- train(</pre>
                      form = type ~ .,
                      data = datos_train[c("type", filtrado_s2n_30)],
                      method = "svmRadial",
                      tuneGrid = hiperparametros,
                      metric = "Accuracy",
                      trControl = control train
registerDoParallel(cores = 1)
saveRDS(object = symrad s2n 30, file = "symrad s2n 30.rds")
svmrad s2n 30
## Support Vector Machines with Radial Basis Function Kernel
## 49 samples
## 10 predictors
## 4 classes: 'CIS', 'PP', 'RR', 'SP'
##
## No pre-processing
## Resampling: Bootstrapped (50 reps)
## Summary of sample sizes: 49, 49, 49, 49, 49, ...
## Resampling results across tuning parameters:
##
##
     sigma C
                  Accuracy
                             Kappa
     1e-04
##
              10 0.4769564 0.009714286
##
     1e-04
             50 0.6648663 0.402539057
##
     1e-04
           100 0.6966755 0.464503611
##
     1e-04
           200 0.7100331 0.499058760
##
     1e-04
             600 0.6779873 0.486986496
           800 0.6764801 0.493523617
##
     1e-04
##
     1e-04 1000 0.6672388 0.483504339
     1e-04 1500 0.6517586 0.469170081
##
##
     1e-03
            10 0.6966755 0.464503611
##
     1e-03
              50 0.6890635 0.498065252
##
     1e-03 100 0.6649055 0.479133741
##
     1e-03 200 0.6439611 0.462105554
##
     1e-03
             600 0.6273788 0.444329426
```

```
1e-03
                   0.6275152 0.445678473
##
              800
##
     1e-03 1000 0.6302944 0.448523190
##
     1e-03 1500 0.6295012 0.446742484
##
     1e-02
               10
                   0.6637464
                               0.478358819
##
     1e-02
               50 0.6248017
                               0.438119899
##
     1e-02
              100 0.6228527
                               0.437842916
##
     1e-02
              200 0.6241604
                               0.444385364
##
     1e-02
              600 0.6319136 0.458254620
##
     1e-02
              800 0.6338191 0.460649282
     1e-02 1000 0.6314159
##
                               0.457549648
##
     1e-02 1500 0.6314191 0.454872180
##
## Accuracy was used to select the optimal model using the largest value.
## The final values used for the model were sigma = 1e-04 and C = 200.
ggplot(svmrad s2n 30, highlight = TRUE) +
  labs(title = "Evolución del accuracy del modelo SVM Radial") +
  theme_bw()
   Evolución del accuracy del modelo SVM Radial
 0.70
 0.65
(Bootstrap)
                                                                     Sigma
Accuracy (
                                                                      - 1e-03
                                                                     1e-04
 0.50
                                  Cost
6.1.6. Reducción PCA
# PARALELIZACIÓN DE PROCESO
registerDoParallel(cores = 3)
# HIPERPARÁMETROS, NÚMERO DE REPETICIONES Y SEMILLAS PARA CADA REPETICIÓN
repeticiones boot <- 50
# Hiperparámetros
hiperparametros \leftarrow expand.grid(sigma = c(0.001, 0.01, 0.1),
                                 C = c(1, 20, 50, 100, 200, 500, 1000,
1500, 2000))
set.seed(123)
seeds <- vector(mode = "list", length = repeticiones_boot + 1)</pre>
for (i in 1:repeticiones boot) {
  seeds[[i]] <- sample.int(1000, nrow(hiperparametros))</pre>
}
```

```
seeds[[repeticiones_boot + 1]] <- sample.int(1000, 1)</pre>
# DEFINICIÓN DEL ENTRENAMIENTO
control train <- trainControl(method = "boot", number =</pre>
repeticiones boot,
                              seeds = seeds, returnResamp = "final",
                              verboseIter = FALSE, allowParallel = TRUE)
# AJUSTE DEL MODELO
set.seed(342)
svmrad_pca <- train(form = type ~ .,</pre>
                      data = datos train pca,
                      method = "svmRadial",
                      tuneGrid = hiperparametros,
                      metric = "Accuracy",
                     trControl = control train)
registerDoParallel(cores = 1)
saveRDS(object = svmrad pca, file = "svmrad pca.rds")
svmrad_pca
## Support Vector Machines with Radial Basis Function Kernel
##
## 49 samples
## 46 predictors
## 4 classes: 'CIS', 'PP', 'RR', 'SP'
##
## No pre-processing
## Resampling: Bootstrapped (50 reps)
## Summary of sample sizes: 49, 49, 49, 49, 49, ...
## Resampling results across tuning parameters:
##
                  Accuracy
##
    sigma C
                             Kappa
##
    0.001
              1 0.4736231 0.0004081633
              20 0.4492847 0.0154918078
##
    0.001
##
    0.001
              50 0.4482391 0.0210599500
##
    0.001
            100 0.4482391
                             0.0210599500
##
    0.001
            200 0.4482391
                              0.0210599500
    0.001
##
            500 0.4482391
                              0.0210599500
##
    0.001 1000 0.4482391
                              0.0210599500
##
    0.001 1500 0.4482391
                              0.0210599500
    0.001 2000 0.4482391
##
                              0.0210599500
##
    0.010
              1 0.4699213 -0.0077414960
##
    0.010
              20 0.4782170
                             0.0252188278
##
    0.010
             50 0.4782170
                              0.0252188278
##
    0.010
            100 0.4782170
                              0.0252188278
##
    0.010
             200 0.4782170
                              0.0252188278
##
    0.010
             500 0.4782170
                              0.0252188278
##
    0.010 1000 0.4782170
                              0.0252188278
##
    0.010 1500 0.4782170
                              0.0252188278
```

```
0.010
            2000
                  0.4782170
                              0.0252188278
##
##
     0.100
               1
                  0.4841459
                              0.0000000000
##
     0.100
              20
                  0.4841459
                              0.0000000000
##
     0.100
              50
                  0.4841459
                              0.0000000000
     0.100
                  0.4841459
##
             100
                              0.000000000
##
     0.100
             200
                  0.4841459
                              0.0000000000
##
     0.100
             500
                  0.4841459
                              0.0000000000
##
     0.100
            1000
                  0.4841459
                              0.0000000000
##
     0.100
            1500
                  0.4841459
                              0.0000000000
##
     0.100
            2000
                  0.4841459
                              0.0000000000
##
## Accuracy was used to select the optimal model using the largest value.
## The final values used for the model were sigma = 0.1 and C = 1.
ggplot(svmrad pca, highlight = TRUE) +
  labs(title = "Evolución del accuracy del modelo SVM Radial") +
  theme_bw()
```



6.2. Random Forest

El método ranger de caret emplea la función ranger() del paquete ranger. Este algoritmo tiene 3 hiperparámetros:

- mtry: número predictores seleccionados aleatoriamente en cada árbol.
- min.node.size: tamaño mínimo que tiene que tener un nodo para poder ser dividido.
- splitrule: criterio de división.

```
6.2.1. Filtrado por ANOVA p-value 100
library(ranger)
# PARALELIZACIÓN DE PROCESO
registerDoParallel(cores = 3)
```

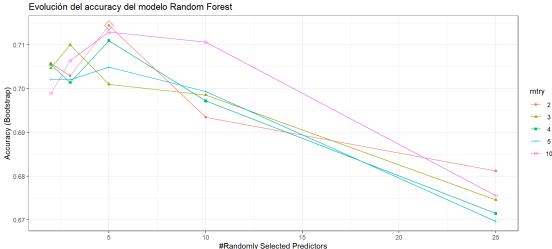
```
# HIPERPARÁMETROS, NÚMERO DE REPETICIONES Y SEMILLAS PARA CADA REPETICIÓN
repeticiones_boot <- 50
# Hiperparámetros
hiperparametros \leftarrow expand.grid(mtry = c(2, 5, 10, 50),
                                min.node.size = c(2, 3, 4, 5, 10),
                                splitrule = "gini")
set.seed(123)
seeds <- vector(mode = "list", length = repeticiones_boot + 1)</pre>
for (i in 1:repeticiones_boot) {
  seeds[[i]] <- sample.int(1000, nrow(hiperparametros))</pre>
}
seeds[[repeticiones_boot + 1]] <- sample.int(1000, 1)</pre>
# DEFINICIÓN DEL ENTRENAMIENTO
control train <- trainControl(method = "boot", number =</pre>
repeticiones boot,
                               seeds = seeds, returnResamp = "final",
                               verboseIter = FALSE, allowParallel = TRUE)
# AJUSTE DEL MODELO
set.seed(342)
rf_pvalue_100 <- train(</pre>
                  form = type ~ .,
                  data = datos_train[c("type",
filtrado_anova_pvalue_100)],
                  method = "ranger",
                  tuneGrid = hiperparametros,
                  metric = "Accuracy",
                  trControl = control train,
                  # Número de árboles ajustados
                  num.trees = 500)
saveRDS(object = rf_pvalue_100, file = "rf_pvalue_100.rds")
registerDoParallel(cores = 1)
rf_pvalue 100
## Random Forest
##
## 49 samples
## 100 predictors
   4 classes: 'CIS', 'PP', 'RR', 'SP'
##
##
## No pre-processing
## Resampling: Bootstrapped (50 reps)
## Summary of sample sizes: 49, 49, 49, 49, 49, ...
## Resampling results across tuning parameters:
##
```

```
##
     mtry
           min.node.size Accuracy
                                        Kappa
##
      2
             2
                            0.6798472
                                        0.4300736
##
      2
             3
                            0.6770080
                                        0.4256451
##
      2
             4
                            0.6739027
                                        0.4204609
      2
             5
##
                            0.6766081
                                        0.4270578
      2
##
            10
                            0.6776438
                                        0.4270945
      5
             2
##
                            0.6806641
                                        0.4298455
      5
##
             3
                            0.6919310 0.4570252
##
      5
             4
                            0.6899081
                                        0.4493900
      5
##
             5
                            0.6851499
                                        0.4395209
      5
##
            10
                            0.6975859
                                        0.4667225
##
     10
             2
                            0.6798315
                                        0.4336897
             3
##
     10
                            0.6790634
                                        0.4345710
##
     10
                            0.6853509
             4
                                        0.4387644
##
     10
             5
                                        0.4208001
                            0.6765904
##
     10
            10
                            0.6814090
                                        0.4385253
##
     50
             2
                            0.6449321
                                        0.3800940
##
     50
             3
                            0.6432133
                                        0.3694895
##
     50
             4
                            0.6352505
                                        0.3600726
##
     50
             5
                            0.6432412
                                        0.3724686
##
     50
            10
                            0.6507881
                                        0.3947245
##
## Tuning parameter 'splitrule' was held constant at a value of gini
## Accuracy was used to select the optimal model using the largest value.
## The final values used for the model were mtry = 5, splitrule = gini
    and min.node.size = 10.
ggplot(rf_pvalue_100, highlight = TRUE) +
  labs(title = "Evolución del accuracy del modelo Random Forest") +
  guides(color = guide_legend(title = "mtry"),
          shape = guide legend(title = "mtry")) +
  theme bw()
   Evolución del accuracy del modelo Random Forest
 0.68
Accuracy (Bootstrap)
                                                                       mtry
                                                                        - 10
 0.64
```

Minimal Node Size

```
6.2.2. Filtrado por ANOVA p-value 50
# PARALELIZACIÓN DE PROCESO
registerDoParallel(cores = 3)
# HIPERPARÁMETROS, NÚMERO DE REPETICIONES Y SEMILLAS PARA CADA REPETICIÓN
repeticiones_boot <- 50
# Hiperparámetros
hiperparametros \leftarrow expand.grid(mtry = c(2, 3, 5, 10, 25),
                                min.node.size = c(2, 3, 4, 5, 10),
                                splitrule = "gini")
set.seed(123)
seeds <- vector(mode = "list", length = repeticiones boot + 1)</pre>
for (i in 1:repeticiones_boot) {
  seeds[[i]] <- sample.int(1000, nrow(hiperparametros))</pre>
}
seeds[[repeticiones_boot + 1]] <- sample.int(1000, 1)</pre>
# DEFINICIÓN DEL ENTRENAMIENTO
control_train <- trainControl(method = "boot", number =</pre>
repeticiones boot,
                               seeds = seeds, returnResamp = "final",
                               verboseIter = FALSE, allowParallel = TRUE)
# AJUSTE DEL MODELO
set.seed(342)
rf_pvalue_50 <- train(
                   form = type ~ .,
                   data = datos train[c("type",
filtrado_anova_pvalue_50)],
                   method = "ranger",
                   tuneGrid = hiperparametros,
                   metric = "Accuracy",
                   trControl = control_train,
                   # Número de árboles ajustados
                   num.trees = 500)
saveRDS(object = rf_pvalue_50, file = "rf_pvalue_50.rds")
registerDoParallel(cores = 1)
rf_pvalue_50
## Random Forest
##
## 49 samples
## 50 predictors
## 4 classes: 'CIS', 'PP', 'RR', 'SP'
## No pre-processing
## Resampling: Bootstrapped (50 reps)
```

```
## Summary of sample sizes: 49, 49, 49, 49, 49, ...
## Resampling results across tuning parameters:
##
     mtry min.node.size Accuracy
                                     Kappa
##
      2
            2
                          0.7057514 0.4794300
##
      2
            3
                          0.7046865
                                     0.4785506
      2
            4
##
                          0.7055347
                                     0.4784795
##
      2
            5
                          0.7020731 0.4737850
##
      2
           10
                          0.6988543 0.4620093
##
      3
            2
                          0.7029384
                                     0.4750800
##
      3
            3
                          0.7099977
                                     0.4912363
##
      3
            4
                          0.7014027
                                     0.4699436
            5
##
      3
                          0.7020090 0.4742648
##
      3
           10
                          0.7063730 0.4819185
##
      5
            2
                          0.7144791
                                     0.4988873
##
      5
            3
                          0.7010057
                                     0.4722598
##
      5
            4
                          0.7109608 0.4870895
##
      5
            5
                          0.7048977
                                     0.4857207
      5
##
           10
                          0.7129178 0.4963112
##
     10
            2
                          0.6934587
                                     0.4566851
            3
##
     10
                          0.6985381
                                     0.4705741
##
     10
            4
                          0.6972005 0.4639143
            5
##
     10
                          0.6993348 0.4752093
##
     10
                          0.7106357
                                     0.4924550
           10
##
     25
            2
                          0.6811648 0.4349853
##
     25
            3
                          0.6745766 0.4292462
##
     25
            4
                          0.6714557
                                     0.4163299
##
     25
            5
                          0.6696896
                                     0.4172944
##
     25
                          0.6755583 0.4349199
##
## Tuning parameter 'splitrule' was held constant at a value of gini
## Accuracy was used to select the optimal model using the largest value.
## The final values used for the model were mtry = 5, splitrule = gini
  and min.node.size = 2.
ggplot(rf_pvalue_50, highlight = TRUE) +
  labs(title = "Evolución del accuracy del modelo Random Forest") +
  guides(color = guide legend(title = "mtry"),
         shape = guide legend(title = "mtry")) +
  theme_bw()
```



#Randomly Selected Predictors 6.2.3. Filtrado por ANOVA p-value 25 # PARALELIZACIÓN DE PROCESO registerDoParallel(cores = 3) # HIPERPARÁMETROS, NÚMERO DE REPETICIONES Y SEMILLAS PARA CADA REPETICIÓN repeticiones_boot <- 50 # Hiperparámetros hiperparametros \leftarrow expand.grid(mtry = c(2, 3, 5, 10, 25), min.node.size = c(2, 3, 4, 5, 10), splitrule = "gini") set.seed(123) seeds <- vector(mode = "list", length = repeticiones_boot + 1)</pre> for (i in 1:repeticiones boot) { seeds[[i]] <- sample.int(1000, nrow(hiperparametros))</pre> } seeds[[repeticiones_boot + 1]] <- sample.int(1000, 1)</pre> # DEFINICIÓN DEL ENTRENAMIENTO control_train <- trainControl(method = "boot", number =</pre> repeticiones_boot, seeds = seeds, returnResamp = "final", verboseIter = FALSE, allowParallel = TRUE) # AJUSTE DEL MODELO set.seed(342) rf_pvalue_25 <- train(</pre> form = type ~ ., data = datos_train[c("type", filtrado_anova_pvalue_25)], method = "ranger", tuneGrid = hiperparametros, metric = "Accuracy",

```
trControl = control_train,
                  # Número de árboles ajustados
                  num.trees = 500)
saveRDS(object = rf_pvalue_25, file = "rf_pvalue_25.rds")
registerDoParallel(cores = 1)
rf_pvalue_25
## Random Forest
##
## 49 samples
## 25 predictors
## 4 classes: 'CIS', 'PP', 'RR', 'SP'
##
## No pre-processing
## Resampling: Bootstrapped (50 reps)
## Summary of sample sizes: 49, 49, 49, 49, 49, ...
## Resampling results across tuning parameters:
##
##
           min.node.size Accuracy
     mtry
                                      Kappa
##
      2
            2
                          0.7268851 0.5186574
      2
            3
##
                          0.7204773 0.5081968
##
      2
            4
                          0.7190363
                                     0.5030187
      2
            5
##
                          0.7108438 0.4909260
      2
##
           10
                          0.7137548
                                     0.4965100
      3
##
            2
                          0.7251496 0.5185306
##
      3
            3
                          0.7140901
                                      0.5009942
##
      3
            4
                          0.7161273 0.5033781
      3
            5
##
                          0.7241531
                                     0.5168568
##
      3
           10
                          0.7162661
                                     0.5041587
      5
##
            2
                          0.7163468 0.5069336
      5
            3
##
                          0.7192578 0.5156517
      5
##
            4
                          0.7126411
                                     0.5016437
      5
            5
##
                          0.7165796
                                     0.5093218
##
      5
           10
                          0.7120131
                                     0.5029672
##
     10
            2
                          0.6801762
                                     0.4548959
##
     10
            3
                          0.6865149 0.4668726
                                     0.4688182
##
     10
            4
                          0.6901663
##
     10
            5
                          0.6866384
                                     0.4714100
##
     10
           10
                          0.6910156
                                     0.4807366
##
     25
            2
                          0.6310817
                                      0.3790040
            3
##
     25
                          0.6335705
                                     0.3844626
     25
            4
##
                                      0.3803898
                          0.6306200
##
     25
            5
                          0.6300370
                                     0.3819064
     25
##
           10
                          0.6225092
                                     0.3696509
##
## Tuning parameter 'splitrule' was held constant at a value of gini
## Accuracy was used to select the optimal model using the largest value.
## The final values used for the model were mtry = 2, splitrule = gini
## and min.node.size = 2.
```

```
ggplot(rf_pvalue_25, highlight = TRUE) +
  labs(title = "Evolución del accuracy del modelo Random Forest") +
  guides(color = guide_legend(title = "mtry"),
          shape = guide legend(title = "mtry")) +
  theme_bw()
    Evolución del accuracy del modelo Random Forest
 0.725
 0.700
(Bootstrap)
 0.650
                                                      20
                              #Randomly Selected Predictors
6.2.4. Filtrado por S2N 60
# PARALELIZACIÓN DE PROCESO
registerDoParallel(cores = 3)
# HIPERPARÁMETROS, NÚMERO DE REPETICIONES Y SEMILLAS PARA CADA REPETICIÓN
repeticiones_boot <- 50
# Hiperparámetros
hiperparametros \leftarrow expand.grid(mtry = c(5, 7, 10, 15, 17),
                                  min.node.size = c(2, 3, 5, 10, 15, 20),
                                  splitrule = "gini")
set.seed(123)
seeds <- vector(mode = "list", length = repeticiones_boot + 1)</pre>
for (i in 1:repeticiones_boot) {
  seeds[[i]] <- sample.int(1000, nrow(hiperparametros))</pre>
seeds[[repeticiones_boot + 1]] <- sample.int(1000, 1)</pre>
# DEFINICIÓN DEL ENTRENAMIENTO
control train <- trainControl(method = "boot", number =</pre>
repeticiones boot,
                                 seeds = seeds, returnResamp = "final",
                                 verboseIter = FALSE, allowParallel = TRUE)
# AJUSTE DEL MODELO
set.seed(342)
rf_s2n_60 <- train(
```

```
form = type ~ .,
                data = datos_train[c("type", filtrado_s2n_60)],
                method = "ranger",
                tuneGrid = hiperparametros,
                metric = "Accuracy",
                trControl = control_train,
                # Número de árboles ajustados
                num.trees = 500
              )
saveRDS(object = rf s2n 60, file = "rf s2n 60.rds")
registerDoParallel(cores = 1)
rf_s2n_60
## Random Forest
##
## 49 samples
## 20 predictors
## 4 classes: 'CIS', 'PP', 'RR', 'SP'
##
## No pre-processing
## Resampling: Bootstrapped (50 reps)
## Summary of sample sizes: 49, 49, 49, 49, 49, ...
## Resampling results across tuning parameters:
##
     mtry min.node.size Accuracy
##
                                      Kappa
##
      5
            2
                          0.6685457
                                     0.4409409
##
      5
            3
                          0.6788081
                                     0.4618042
      5
            5
##
                          0.6705095
                                     0.4473356
##
      5
           10
                          0.6587297
                                     0.4355933
      5
##
           15
                          0.6638268 0.4399565
      5
##
           20
                          0.6581549 0.4314073
##
      7
            2
                          0.6577532
                                     0.4337402
      7
##
            3
                          0.6668044
                                     0.4447252
##
      7
            5
                          0.6607570 0.4361864
##
      7
           10
                          0.6555020 0.4349191
      7
##
           15
                          0.6470919 0.4211900
      7
           20
##
                          0.6451377 0.4199913
##
     10
            2
                          0.6447452 0.4136643
##
     10
            3
                          0.6492153 0.4247465
            5
##
     10
                          0.6416606 0.4103971
##
     10
           10
                          0.6346241
                                     0.4032295
##
     10
           15
                          0.6264952
                                     0.3965604
           20
##
     10
                          0.6255049 0.3966521
     15
            2
##
                          0.6246667
                                      0.3864101
##
     15
            3
                          0.6268347
                                     0.3874754
            5
##
     15
                          0.6264175
                                     0.3881988
##
     15
           10
                          0.6182825 0.3852780
##
     15
           15
                          0.6142671 0.3858374
##
     15
           20
                          0.5984971 0.3595038
```

```
0.6259446 0.3844910
##
     17
             2
##
     17
             3
                            0.6198851 0.3768644
                            0.6175723 0.3721508
##
     17
             5
##
     17
            10
                            0.6212337
                                        0.3864994
##
     17
            15
                            0.6086247 0.3758128
##
     17
            20
                            0.5989272 0.3601710
##
## Tuning parameter 'splitrule' was held constant at a value of gini
## Accuracy was used to select the optimal model using the largest value.
## The final values used for the model were mtry = 5, splitrule = gini
  and min.node.size = 3.
ggplot(rf s2n 60, highlight = TRUE) +
  labs(title = "Evolución del accuracy del modelo Random Forest") +
  guides(color = guide legend(title = "mtry"),
          shape = guide legend(title = "mtry")) +
  theme_bw()
   Evolución del accuracy del modelo Random Forest
 0.68
 0.66
(Bootstrap)
                                                                        mtry
Accuracy
 0.62
 0.60
                                Minimal Node Size
6.2.5. Filtrado por S2N 30
# PARALELIZACIÓN DE PROCESO
registerDoParallel(cores = 3)
# HIPERPARÁMETROS, NÚMERO DE REPETICIONES Y SEMILLAS PARA CADA REPETICIÓN
repeticiones_boot <- 50
# Hiperparámetros
hiperparametros \leftarrow expand.grid(mtry = c(1,3,5, 7, 10),
                                  min.node.size = c(2, 3, 5, 10, 15, 20),
                                  splitrule = "gini")
set.seed(123)
seeds <- vector(mode = "list", length = repeticiones boot + 1)</pre>
for (i in 1:repeticiones boot) {
  seeds[[i]] <- sample.int(1000, nrow(hiperparametros))</pre>
```

```
seeds[[repeticiones_boot + 1]] <- sample.int(1000, 1)</pre>
# DEFINICIÓN DEL ENTRENAMIENTO
control train <- trainControl(method = "boot", number =</pre>
repeticiones_boot,
                              seeds = seeds, returnResamp = "final",
                              verboseIter = FALSE, allowParallel = TRUE)
# AJUSTE DEL MODELO
set.seed(342)
rf_s2n_30 <- train(
                form = type ~ .,
                data = datos_train[c("type", filtrado_s2n_30)],
                method = "ranger",
                tuneGrid = hiperparametros,
                metric = "Accuracy",
                trControl = control_train,
                # Número de árboles ajustados
                num.trees = 500
              )
saveRDS(object = rf_s2n_30, file = "rf_s2n_30.rds")
registerDoParallel(cores = 1)
rf_s2n_30
## Random Forest
##
## 49 samples
## 10 predictors
## 4 classes: 'CIS', 'PP', 'RR', 'SP'
##
## No pre-processing
## Resampling: Bootstrapped (50 reps)
## Summary of sample sizes: 49, 49, 49, 49, 49, ...
## Resampling results across tuning parameters:
##
##
     mtry min.node.size Accuracy
                                      Kappa
##
      1
            2
                          0.7106013 0.5089746
##
      1
            3
                          0.7091867 0.5056827
            5
      1
##
                          0.6991224 0.4871032
##
      1
                          0.6939435 0.4773066
           10
##
           15
      1
                          0.6891206 0.4630077
##
           20
      1
                          0.6726367 0.4310457
##
      3
            2
                          0.6724810 0.4529313
##
      3
            3
                          0.6719120 0.4486945
      3
##
           5
                          0.6729120 0.4480963
      3
##
           10
                          0.6699596 0.4424375
      3
##
           15
                          0.6645006 0.4366850
      3
##
           20
                          0.6610055 0.4284100
```

```
0.6526503 0.4243360
##
      5
             2
##
      5
             3
                            0.6493064 0.4201802
      5
##
             5
                            0.6575539 0.4308684
      5
##
            10
                            0.6543695
                                        0.4248813
      5
##
            15
                            0.6311484
                                        0.3929160
##
      5
            20
                            0.6195337
                                        0.3763852
      7
##
             2
                            0.6377689
                                        0.4048068
      7
##
             3
                            0.6402012 0.4071014
##
      7
             5
                            0.6368917
                                        0.3994751
##
      7
            10
                            0.6251468
                                        0.3823249
##
      7
            15
                            0.6093747
                                        0.3656798
##
      7
            20
                            0.5987573 0.3523871
##
     10
             2
                            0.6240269 0.3831052
##
             3
     10
                            0.6202955 0.3747041
             5
##
     10
                            0.6185685
                                        0.3726282
##
     10
            10
                            0.6063503
                                        0.3593849
##
            15
                            0.5860059 0.3352943
     10
##
     10
            20
                            0.5742160 0.3199542
##
## Tuning parameter 'splitrule' was held constant at a value of gini
## Accuracy was used to select the optimal model using the largest value.
## The final values used for the model were mtry = 1, splitrule = gini
    and min.node.size = 2.
##
ggplot(rf_s2n_30, highlight = TRUE) +
  labs(title = "Evolución del accuracy del modelo Random Forest") +
  guides(color = guide_legend(title = "mtry"),
          shape = guide_legend(title = "mtry")) +
  theme bw()
   Evolución del accuracy del modelo Random Forest
Accuracy (Bootstrap)
                                                                        mtry
 0.60
                                                  15
                                Minimal Node Size
```

6.2.6. Reducción PCA # PARALELIZACIÓN DE PROCESO registerDoParallel(cores = 3)

```
repeticiones_boot <- 50
# Hiperparámetros
hiperparametros \leftarrow expand.grid(mtry = c(5, 10, 25, 30),
                                min.node.size = c(2, 3, 4, 5, 10),
                                splitrule = "gini")
set.seed(123)
seeds <- vector(mode = "list", length = repeticiones_boot + 1)</pre>
for (i in 1:repeticiones_boot) {
  seeds[[i]] <- sample.int(1000, nrow(hiperparametros))</pre>
seeds[[repeticiones_boot + 1]] <- sample.int(1000, 1)</pre>
# DEFINICIÓN DEL ENTRENAMIENTO
control train <- trainControl(method = "boot", number =</pre>
repeticiones boot,
                               seeds = seeds, returnResamp = "final",
                               verboseIter = FALSE, allowParallel = TRUE)
# AJUSTE DEL MODELO
set.seed(342)
rf_pca <- train(
            form = type ~ .,
            data = datos train pca,
            method = "ranger",
            tuneGrid = hiperparametros,
            metric = "Accuracy",
            trControl = control train,
            # Número de árboles ajustados
            num.trees = 500)
saveRDS(object = rf pca, file = "rf pca.rds")
registerDoParallel(cores = 1)
rf_pca
## Random Forest
##
## 49 samples
## 46 predictors
## 4 classes: 'CIS', 'PP', 'RR', 'SP'
##
## No pre-processing
## Resampling: Bootstrapped (50 reps)
## Summary of sample sizes: 49, 49, 49, 49, 49, ...
## Resampling results across tuning parameters:
##
##
     mtry min.node.size Accuracy
                                      Kappa
##
      5
            2
                          0.4297329 -0.04334187
      5
            3
                          0.4375212 -0.02665502
##
```

```
0.4483812
##
      5
             4
                                         -0.01559800
##
      5
             5
                             0.4408445
                                         -0.02258052
      5
                             0.4375119
##
            10
                                         -0.02980272
##
     10
             2
                             0.4073832
                                         -0.06659585
             3
##
                             0.4123192
     10
                                         -0.05684472
##
     10
             4
                             0.4096022
                                         -0.05900057
             5
##
     10
                             0.4115755
                                         -0.05254642
##
     10
            10
                             0.4025760
                                         -0.05266537
##
     25
             2
                             0.3772842
                                         -0.07865664
##
             3
     25
                             0.3742560
                                         -0.07932350
##
     25
             4
                             0.3763932
                                         -0.07543047
##
     25
             5
                             0.3751794
                                         -0.08186112
##
     25
            10
                             0.3675643
                                         -0.07356611
##
             2
     30
                             0.3651116
                                         -0.08504378
##
             3
     30
                             0.3713938
                                         -0.07476173
##
     30
             4
                             0.3758135
                                         -0.07031013
##
     30
             5
                             0.3657506
                                         -0.08316182
##
     30
            10
                             0.3491711
                                         -0.09337689
##
## Tuning parameter 'splitrule' was held constant at a value of gini
## Accuracy was used to select the optimal model using the largest value.
## The final values used for the model were mtry = 5, splitrule = gini
    and min.node.size = 4.
##
ggplot(rf_pca, highlight = TRUE) +
  labs(title = "Evolución del accuracy del modelo Random Forest") +
  guides(color = guide_legend(title = "mtry"),
          shape = guide legend(title = "mtry")) +
  theme bw()
    Evolución del accuracy del modelo Random Forest
 0.450
 0.425
Accuracy (Bootstrap)
 0.375
 0.350
                                  Minimal Node Size
```

6.3. Neural Network

El método nnet de caret emplea la función nnet() del paquete nnet para crear redes neuronales con una capa oculta. Este algoritmo tiene 2 hiperparámetros:

- size: número de neuronas en la capa oculta.
- decay: controla la regularización durante el entrenamiento de la red.

En vista de los resultados obtenidos con los algoritmos anteriores, no se empleará el filtrado por reducción PCA.

```
6.3.1. Filtrado por S2N 60
# PARALELIZACIÓN DE PROCESO
registerDoParallel(cores = 3)
# HIPERPARÁMETROS, NÚMERO DE REPETICIONES Y SEMILLAS PARA CADA REPETICIÓN
repeticiones_boot <- 50
# Hiperparámetros
hiperparametros \leftarrow expand.grid(size = c(5, 10, 15, 20, 40),
                                decay = c(0.01, 0.1)
set.seed(123)
seeds <- vector(mode = "list", length = repeticiones_boot + 1)</pre>
for (i in 1:repeticiones boot) {
  seeds[[i]] <- sample.int(1000, nrow(hiperparametros))</pre>
}
seeds[[repeticiones_boot + 1]] <- sample.int(1000, 1)</pre>
# DEFINICIÓN DEL ENTRENAMIENTO
control train <- trainControl(method = "boot", number =</pre>
repeticiones_boot,
                               seeds = seeds, returnResamp = "final",
                               verboseIter = FALSE, allowParallel = TRUE)
# AJUSTE DEL MODELO
set.seed(342)
nnet_s2n_60 <- train(</pre>
                form = type ~ .,
                 data = datos_train[c("type", filtrado_s2n_60)],
                method = "nnet",
                tuneGrid = hiperparametros,
                metric = "Accuracy",
                trControl = control train,
                # Rango de inicialización de los pesos
                rang = c(-0.7, 0.7),
                # Número máximo de pesos
                MaxNWts = 10000,
                # Para que no se muestre cada iteración por pantalla
                trace = FALSE
              )
saveRDS(object = nnet_s2n_60, file = "nnet_s2n_60.rds")
```

```
registerDoParallel(cores = 1)
nnet_s2n_60
## Neural Network
##
## 49 samples
## 20 predictors
   4 classes: 'CIS', 'PP', 'RR', 'SP'
##
## No pre-processing
## Resampling: Bootstrapped (50 reps)
## Summary of sample sizes: 49, 49, 49, 49, 49, ...
## Resampling results across tuning parameters:
##
##
     size decay
                   Accuracy
                               Kappa
##
      5
           0.01
                   0.6495678
                               0.4778446
      5
##
           0.10
                   0.6663865
                               0.4947147
##
     10
           0.01
                   0.6672967
                               0.5004936
##
     10
           0.10
                   0.6809899
                               0.5146938
##
     15
           0.01
                   0.6799743
                               0.5186047
##
     15
           0.10
                   0.6955528
                               0.5361675
##
     20
           0.01
                   0.6753407
                               0.5126087
           0.10
##
     20
                   0.6899188
                               0.5298255
##
     40
           0.01
                   0.6732396
                               0.5084195
##
     40
           0.10
                   0.6838120 0.5210241
##
## Accuracy was used to select the optimal model using the largest value.
## The final values used for the model were size = 15 and decay = 0.1.
ggplot(nnet_s2n_60, highlight = TRUE) +
  labs(title = "Evolución del accuracy del modelo NNET") +
  theme_bw()
   Evolución del accuracy del modelo NNET
 0.69
Accuracy (Bootstrap)
                                                                   Weight Decay
```

#Hidden Units

0.66

0.65

→ 0.01 0.10

```
6.3.2. Filtrado por S2N 30
# PARALELIZACIÓN DE PROCESO
registerDoParallel(cores = 3)
# HIPERPARÁMETROS, NÚMERO DE REPETICIONES Y SEMILLAS PARA CADA REPETICIÓN
repeticiones boot <- 50
# Hiperparámetros
hiperparametros \leftarrow expand.grid(size = c(5, 10, 20, 30, 45),
                                decay = c(0.01, 0.1)
set.seed(123)
seeds <- vector(mode = "list", length = repeticiones_boot + 1)</pre>
for (i in 1:repeticiones boot) {
  seeds[[i]] <- sample.int(1000, nrow(hiperparametros))</pre>
}
seeds[[repeticiones_boot + 1]] <- sample.int(1000, 1)</pre>
# DEFINICIÓN DEL ENTRENAMIENTO
control_train <- trainControl(method = "boot", number =</pre>
repeticiones_boot,
                               seeds = seeds, returnResamp = "final",
                               verboseIter = FALSE, allowParallel = TRUE)
# AJUSTE DEL MODELO
set.seed(342)
nnet_s2n_30 <- train(</pre>
                form = type ~ .,
                 data = datos_train[c("type", filtrado_s2n_30)],
                method = "nnet",
                tuneGrid = hiperparametros,
                metric = "Accuracy",
                trControl = control train,
                # Rango de inicialización de los pesos
                rang = c(-0.7, 0.7),
                # Número máximo de pesos
                MaxNWts = 10000,
                # Para que no se muestre cada iteración por pantalla
                trace = FALSE
               )
saveRDS(object = nnet_s2n_30, file = "nnet_s2n_30.rds")
registerDoParallel(cores = 1)
nnet s2n 30
## Neural Network
##
## 49 samples
## 10 predictors
## 4 classes: 'CIS', 'PP', 'RR', 'SP'
```

```
##
## No pre-processing
## Resampling: Bootstrapped (50 reps)
## Summary of sample sizes: 49, 49, 49, 49, 49, ...
## Resampling results across tuning parameters:
##
##
           decay
     size
                   Accuracy
                               Kappa
##
      5
            0.01
                   0.6447627
                               0.4574065
##
      5
           0.10
                   0.6694483
                               0.4883429
##
     10
           0.01
                   0.6521323
                               0.4698893
##
     10
           0.10
                   0.6674295
                               0.4873935
##
     20
           0.01
                   0.6655785
                               0.4891172
##
     20
           0.10
                   0.6812023
                               0.5113826
           0.01
##
     30
                   0.6730217
                               0.5028495
           0.10
##
     30
                   0.6856681
                               0.5166723
##
     45
           0.01
                   0.6793071
                               0.5134918
##
     45
           0.10
                   0.6844764 0.5136475
##
## Accuracy was used to select the optimal model using the largest value.
## The final values used for the model were size = 30 and decay = 0.1.
ggplot(nnet_s2n_30, highlight = TRUE) +
  labs(title = "Evolución del accuracy del modelo NNET") +
  theme bw()
   Evolución del accuracy del modelo NNET
 0.68
Accuracy (Bootstrap)
                                                                    Weight Decay
                                                                    0.01
                                                                    0.10
 0.65
                               #Hidden Units
6.3.3. Filtrado por ANOVA p-value 100
# PARALELIZACIÓN DE PROCESO
registerDoParallel(cores = 3)
# HIPERPARÁMETROS, NÚMERO DE REPETICIONES Y SEMILLAS PARA CADA REPETICIÓN
repeticiones boot <- 50
# Hiperparámetros
hiperparametros \leftarrow expand.grid(size = c(5, 10, 20, 30, 45),
                                 decay = c(0.01, 0.1))
```

```
set.seed(123)
seeds <- vector(mode = "list", length = repeticiones_boot + 1)</pre>
for (i in 1:repeticiones_boot) {
  seeds[[i]] <- sample.int(1000, nrow(hiperparametros))</pre>
seeds[[repeticiones boot + 1]] <- sample.int(1000, 1)</pre>
# DEFINICIÓN DEL ENTRENAMIENTO
control train <- trainControl(method = "boot", number =</pre>
repeticiones_boot,
                              seeds = seeds, returnResamp = "final",
                              verboseIter = FALSE, allowParallel = TRUE)
# AJUSTE DEL MODELO
set.seed(342)
nnet pvalue 100 <- train(</pre>
                form = type ~ .,
                data = datos_train[c("type", filtrado_anova_pvalue_100)],
                method = "nnet",
                tuneGrid = hiperparametros,
                metric = "Accuracy",
                trControl = control train,
                # Rango de inicialización de los pesos
                rang = c(-0.7, 0.7),
                # Número máximo de pesos
                MaxNWts = 10000,
                # Para que no se muestre cada iteración por pantalla
                trace = FALSE
              )
saveRDS(object = nnet pvalue 100, file = "nnet pvalue 100.rds")
registerDoParallel(cores = 1)
nnet_pvalue_100
## Neural Network
##
## 49 samples
## 100 predictors
## 4 classes: 'CIS', 'PP', 'RR', 'SP'
##
## No pre-processing
## Resampling: Bootstrapped (50 reps)
## Summary of sample sizes: 49, 49, 49, 49, 49, ...
## Resampling results across tuning parameters:
##
##
     size decay Accuracy
                             Kappa
##
      5
           0.01
                  0.9435589 0.9112923
##
      5
           0.10
                  0.9410170 0.9083058
##
     10
           0.01
                  0.9554087 0.9288216
```

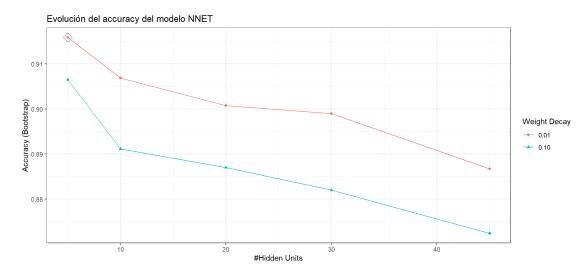
```
0.10
                    0.9360976 0.8993654
##
     10
##
     20
            0.01
                    0.9414546 0.9088895
##
     20
            0.10
                    0.9170129 0.8706031
##
     30
            0.01
                    0.9303129
                                0.8899313
##
     30
            0.10
                    0.9076494
                                0.8548389
##
     45
            0.01
                    0.9270981
                                0.8857888
##
     45
            0.10
                    0.8986172 0.8392153
##
## Accuracy was used to select the optimal model using the largest value.
## The final values used for the model were size = 10 and decay = 0.01.
ggplot(nnet pvalue 100, highlight = TRUE) +
  labs(title = "Evolución del accuracy del modelo NNET") +
  theme_bw()
    Evolución del accuracy del modelo NNET
 0.94
Accuracy (Bootstrap)
                                                                     Weight Decay
                                                                      • 0.01
                                                                      ____ 0.10
 0.90
                            20
                                #Hidden Units
6.3.4. Filtrado por ANOVA p-value 50
# PARALELIZACIÓN DE PROCESO
registerDoParallel(cores = 3)
# HIPERPARÁMETROS, NÚMERO DE REPETICIONES Y SEMILLAS PARA CADA REPETICIÓN
repeticiones_boot <- 50
# Hiperparámetros
hiperparametros \leftarrow expand.grid(size = c(5, 10, 20, 30, 45),
                                  decay = c(0.01, 0.1)
set.seed(123)
seeds <- vector(mode = "list", length = repeticiones_boot + 1)</pre>
for (i in 1:repeticiones_boot) {
  seeds[[i]] <- sample.int(1000, nrow(hiperparametros))</pre>
}
seeds[[repeticiones boot + 1]] <- sample.int(1000, 1)</pre>
```

DEFINICIÓN DEL ENTRENAMIENTO

```
control_train <- trainControl(method = "boot", number =</pre>
repeticiones_boot,
                              seeds = seeds, returnResamp = "final",
                              verboseIter = FALSE, allowParallel = TRUE)
# AJUSTE DEL MODELO
set.seed(342)
nnet_pvalue_50 <- train(</pre>
                form = type ~ .,
                data = datos_train[c("type", filtrado_anova_pvalue_50)],
                method = "nnet",
                tuneGrid = hiperparametros,
                metric = "Accuracy",
                trControl = control_train,
                # Rango de inicialización de los pesos
                rang = c(-0.7, 0.7),
                # Número máximo de pesos
                MaxNWts = 10000,
                # Para que no se muestre cada iteración por pantalla
               trace = FALSE
              )
saveRDS(object = nnet_pvalue_50, file = "nnet_pvalue_50.rds")
registerDoParallel(cores = 1)
nnet_pvalue_50
## Neural Network
##
## 49 samples
## 50 predictors
## 4 classes: 'CIS', 'PP', 'RR', 'SP'
##
## No pre-processing
## Resampling: Bootstrapped (50 reps)
## Summary of sample sizes: 49, 49, 49, 49, 49, ...
## Resampling results across tuning parameters:
##
##
     size decay Accuracy
                             Kappa
##
      5
           0.01
                  0.9159172 0.8692827
##
      5
           0.10
                  0.9065225 0.8498716
##
     10
          0.01
                  0.9068488 0.8509746
##
     10
          0.10
                  0.8911099 0.8229043
##
     20
          0.01
                  0.9007177 0.8410253
##
     20
         0.10
                  0.8869928 0.8144026
##
     30
          0.01
                  0.8989804 0.8362181
##
     30
          0.10
                  0.8819866 0.8057649
##
     45
          0.01
                  0.8866979 0.8159156
##
     45
          0.10
                  0.8724008 0.7893556
##
```

```
## Accuracy was used to select the optimal model using the largest value.
## The final values used for the model were size = 5 and decay = 0.01.
```

```
ggplot(nnet pvalue 50, highlight = TRUE) +
  labs(title = "Evolución del accuracy del modelo NNET") +
  theme bw()
```



6.3.5. Filtrado por ANOVA p-value 25

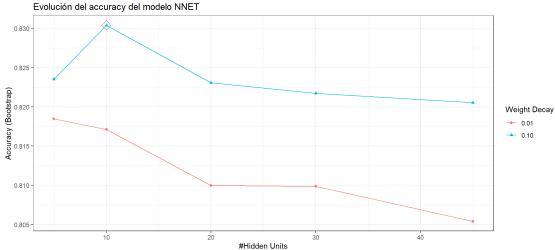
```
# PARALELIZACIÓN DE PROCESO
registerDoParallel(cores = 3)
```

```
# HIPERPARÁMETROS, NÚMERO DE REPETICIONES Y SEMILLAS PARA CADA REPETICIÓN
repeticiones boot <- 50
```

nnet_pvalue_25 <- train(</pre>

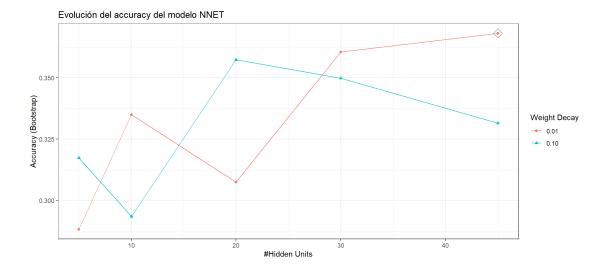
```
# Hiperparámetros
hiperparametros \leftarrow expand.grid(size = c(5, 10, 20, 30, 45),
                                 decay = c(0.01, 0.1)
set.seed(123)
seeds <- vector(mode = "list", length = repeticiones_boot + 1)</pre>
for (i in 1:repeticiones boot) {
  seeds[[i]] <- sample.int(1000, nrow(hiperparametros))</pre>
}
seeds[[repeticiones boot + 1]] <- sample.int(1000, 1)</pre>
# DEFINICIÓN DEL ENTRENAMIENTO
control train <- trainControl(method = "boot", number =</pre>
repeticiones_boot,
                                seeds = seeds, returnResamp = "final",
                                verboseIter = FALSE, allowParallel = TRUE)
# AJUSTE DEL MODELO
set.seed(342)
```

```
form = type ~ .,
                data = datos_train[c("type", filtrado_anova_pvalue_25)],
                method = "nnet",
                tuneGrid = hiperparametros,
                metric = "Accuracy",
                trControl = control_train,
                # Rango de inicialización de los pesos
                rang = c(-0.7, 0.7),
                # Número máximo de pesos
                MaxNWts = 10000,
                # Para que no se muestre cada iteración por pantalla
               trace = FALSE
              )
saveRDS(object = nnet_pvalue_25, file = "nnet_pvalue_25.rds")
registerDoParallel(cores = 1)
nnet_pvalue_25
## Neural Network
##
## 49 samples
## 25 predictors
## 4 classes: 'CIS', 'PP', 'RR', 'SP'
##
## No pre-processing
## Resampling: Bootstrapped (50 reps)
## Summary of sample sizes: 49, 49, 49, 49, 49, ...
## Resampling results across tuning parameters:
##
##
    size decay Accuracy
                             Kappa
##
     5
          0.01
                  0.8184713 0.7014756
                  0.8235256 0.7093696
     5
##
          0.10
##
    10
          0.01
                 0.8171236 0.6990311
          0.10
##
     10
                  0.8303917 0.7199855
##
          0.01
     20
                  0.8099706 0.6865294
##
     20
          0.10
                  0.8230821 0.7069075
##
     30
          0.01
                 0.8098601 0.6859726
          0.10
##
     30
                  0.8217098 0.7046837
##
    45
          0.01
                  0.8054195 0.6778669
##
    45
          0.10
                  0.8205257 0.7023326
##
## Accuracy was used to select the optimal model using the largest value.
## The final values used for the model were size = 10 and decay = 0.1.
ggplot(nnet pvalue 25, highlight = TRUE) +
  labs(title = "Evolución del accuracy del modelo NNET") +
 theme_bw()
```



```
6.3.6. PCA
# PARALELIZACIÓN DE PROCESO
registerDoParallel(cores = 3)
# HIPERPARÁMETROS, NÚMERO DE REPETICIONES Y SEMILLAS PARA CADA REPETICIÓN
repeticiones_boot <- 50
# Hiperparámetros
hiperparametros \leftarrow expand.grid(size = c(5, 10, 20, 30, 45),
                                 decay = c(0.01, 0.1)
set.seed(123)
seeds <- vector(mode = "list", length = repeticiones_boot + 1)</pre>
for (i in 1:repeticiones_boot) {
  seeds[[i]] <- sample.int(1000, nrow(hiperparametros))</pre>
}
seeds[[repeticiones_boot + 1]] <- sample.int(1000, 1)</pre>
# DEFINICIÓN DEL ENTRENAMIENTO
control train <- trainControl(method = "boot", number =</pre>
repeticiones_boot,
                                seeds = seeds, returnResamp = "final",
                                verboseIter = FALSE, allowParallel = TRUE)
# AJUSTE DEL MODELO
set.seed(342)
nnet_pca <- train(</pre>
                 form = type ~ .,
                 data = datos_train_pca,
                 method = "nnet",
                 tuneGrid = hiperparametros,
                 metric = "Accuracy",
                 trControl = control_train,
                 # Rango de inicialización de los pesos
```

```
rang = c(-0.7, 0.7),
                # Número máximo de pesos
                MaxNWts = 10000,
                # Para que no se muestre cada iteración por pantalla
                trace = FALSE
saveRDS(object = nnet_pca, file = "nnet_pca.rds")
registerDoParallel(cores = 1)
nnet_pca
## Neural Network
## 49 samples
## 46 predictors
## 4 classes: 'CIS', 'PP', 'RR', 'SP'
##
## No pre-processing
## Resampling: Bootstrapped (50 reps)
## Summary of sample sizes: 49, 49, 49, 49, 49, ...
## Resampling results across tuning parameters:
##
##
     size decay Accuracy
                             Kappa
##
      5
           0.01
                  0.2883108
                             -0.01194768
      5
##
           0.10
                              0.02224167
                  0.3173675
##
     10
           0.01
                  0.3349564
                              0.03659622
##
     10
           0.10
                  0.2935103
                              0.01291432
##
     20
          0.01
                  0.3075311
                              0.01252888
##
     20
          0.10
                  0.3573166 0.05606175
##
     30
          0.01
                  0.3604769
                              0.06449293
##
     30
           0.10
                  0.3498149
                              0.05640796
##
     45
           0.01
                  0.3681189
                              0.05983224
##
     45
           0.10
                  0.3315225
                              0.03642839
##
## Accuracy was used to select the optimal model using the largest value.
## The final values used for the model were size = 45 and decay = 0.01.
ggplot(nnet_pca, highlight = TRUE) +
  labs(title = "Evolución del accuracy del modelo NNET") +
  theme_bw()
```



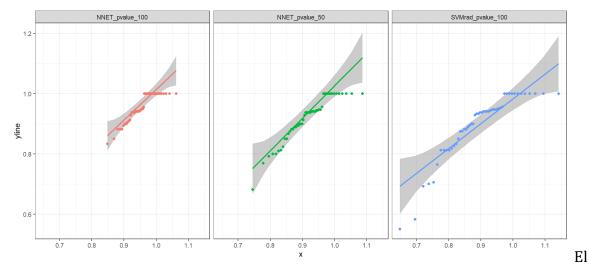
6.4. Comparación de modelos

```
6.4.1. Error de validación
modelos <- list(</pre>
  SVMrad pvalue 100 = svmrad pvalue 100,
  SVMrad_pvalue_50 = svmrad_pvalue_50,
  SVMrad pvalue 25 = svmrad pvalue 25,
  SVMrad s2n 60
                   = svmrad s2n 60,
  SVMrad s2n 30
                    = svmrad s2n 30,
  SVMrad pca
                    = svmrad pca,
  RF pvalue 100
                    = rf pvalue 100,
  RF pvalue 50
                    = rf pvalue 50,
  RF_pvalue_25
                    = rf_pvalue_25,
  RF s2n 60
                    = rf_s2n_60
                    = rf_s2n_30,
  RF_s2n_30
  RF pca
                   = rf pca,
                   = nnet pvalue 100,
  NNET pvalue 100
  NNET pvalue 50
                   = nnet pvalue 50,
  NNET_pvalue_25
                    = nnet_pvalue_25,
  NNET s2n 60
                    = nnet_s2n_60,
  NNET_s2n_30
                    = nnet s2n 30
  )
resultados_resamples <- resamples(modelos)</pre>
# Se trasforma el dataframe devuelto por resamples() para separar el
nombre del modelo y las métricas en columnas distintas.
metricas resamples <- resultados resamples$values %>%
                         gather(key = "modelo", value = "valor", -
Resample) %>%
                         separate(col = "modelo", into = c("modelo",
"metrica"),
                                  sep = "~", remove = TRUE)
```

Accuracy y Kappa promedio de cada modelo

```
promedio_metricas_resamples <- metricas_resamples %>%
  group_by(modelo, metrica) %>%
  summarise(media = mean(valor)) %>%
  spread(key = metrica, value = media) %>%
  arrange(desc(Accuracy))
promedio metricas resamples
metricas resamples %>%
  filter(metrica == "Accuracy") %>%
  group by(modelo) %>%
  summarise(media = mean(valor)) %>%
  ggplot(aes(x = reorder(modelo, media), y = media, label = round(media,
2))) +
    geom_segment(aes(x = reorder(modelo, media), y = 0,
                        xend = modelo, yend = media),
                        color = "grev50") +
    geom point(size = 8, color = "firebrick") +
    geom_text(color = "white", size = 3) +
    scale_y = continuous(limits = c(0, 1)) +
    # Accuracy basal
    geom_hline(yintercept = 0.156, linetype = "dashed") +
    annotate(geom = "text", y = 0.28, x = 12.5, label = "Accuracy basal")
    labs(title = "Validación: Accuracy medio repeated-CV",
          subtitle = "Modelos ordenados por media",
          x = "modelo") +
    coord_flip() +
    theme_bw()
          Validación: Accuracy medio repeated-CV
          Modelos ordenados por media
  NNET pvalue 100
  NNET_pvalue_50 -
 SVMrad_pvalue_100
  SVMrad pvalue 50
  SVMrad pvalue 25
                           Accuracy basal
   NNET pvalue 25
    RF pvalue 25
   SVMrad_s2n_60
   RF_pvalue_50 -
     RF_s2n_30 -
   SVMrad_s2n_30
   RF_pvalue_100 -
    NNET s2n 60
    NNET s2n 30
     RF_s2n_60 -
    SVMrad_pca
      RF_pca -
                                           media
metricas resamples %>% filter(metrica == "Accuracy") %>%
  group by(modelo) %>%
  mutate(media = mean(valor)) %>%
  ungroup() %>%
  ggplot(aes(x = reorder(modelo, media), y = valor, color = modelo)) +
```

```
geom_boxplot(alpha = 0.6, outlier.shape = NA) +
    geom_jitter(width = 0.1, alpha = 0.6) +
    scale_y_continuous(limits = c(0, 1)) +
    # Accuracy basal
    geom hline(yintercept = 0.156, linetype = "dashed") +
    annotate(geom = "text", y = 0.25, x = 12, label = "Accuracy basal") +
    theme bw() +
    labs(title = "Validación: Accuracy medio repeated-CV",
          subtitle = "Modelos ordenados por media") +
    coord flip() +
    theme(legend.position = "none")
          Validación: Accuracy medio repeated-CV
          Modelos ordenados por media
  NNET_pvalue_100
                                                             NNET pvalue 50 -
 SVMrad_pvalue_100 -
  SVMrad pvalue 50 -
  SVMrad_pvalue_25 -
  NNET_pvalue_25 -
                         Accuracy basal
                                                     RF pvalue 25
  SVMrad_s2n_60 -
   RF_pvalue_50 -
    RF_s2n_30 -
                                                    *** . *** . **
  SVMrad_s2n_30 -
                                                    ----
  RF pvalue 100-
                                             NNET_s2n_60 -
   NNET_s2n_30
                                                RF s2n 60-
                                     ***************
    SVMrad_pca -
      RF_pca -
                                           valor
library(qqplotr)
metricas resamples %>%
  filter(modelo %in% c("NNET_pvalue_100", "NNET_pvalue_50",
"SVMrad pvalue_100") &
          metrica == "Accuracy") %>%
  ggplot(aes(sample = valor, color = modelo)) +
    stat_qq_band(alpha = 0.5, color = "gray") +
    stat_qq_line() +
    stat_qq_point() +
    theme bw() +
  theme(legend.position = "none") +
    facet_wrap(~modelo)
```

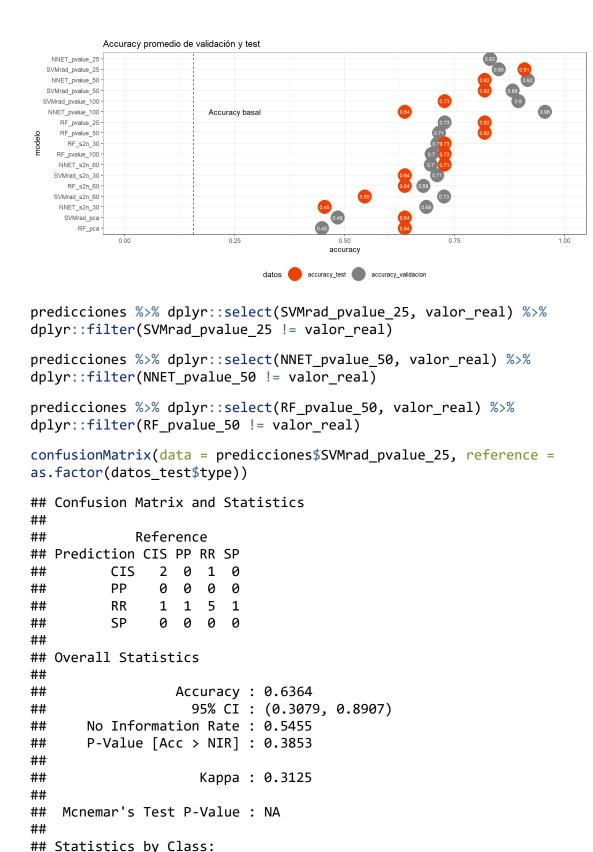


análisis gráfico no muestra grandes desviaciones de la normal, además, dado que se dispone de más de 30 valores por grupo, el t-test tiene cierta robustez. Se procede a comparar los modelos.

```
metricas_ttest <- metricas_resamples %>%
  dplyr::filter(modelo %in% c("SVMrad_pvalue_100","NNET_pvalue_50",
"NNET pvalue 100") &
                  metrica == "Accuracy") %>%
  dplyr::select(-metrica)
pairwise.t.test(x = metricas_ttest$valor,
                g = metricas ttest$modelo,
                paired = TRUE,
                # Al ser solo 2 comparaciones, no se añade ajuste de
p.value
                p.adjust.method = "none")
##
    Pairwise comparisons using paired t tests
##
##
## data: metricas_ttest$valor and metricas_ttest$modelo
##
                     NNET_pvalue_100 NNET_pvalue_50
##
## NNET_pvalue_50
                     0.00042
                                      0.13647
## SVMrad pvalue 100 3.4e-05
##
## P value adjustment method: none
6.4.2. Error de test
predic_svmrad_pvalue_100 <- predict(object = svmrad_pvalue_100, newdata =</pre>
datos_test)
predic svmrad pvalue 50 <- predict(object = svmrad pvalue 50, newdata =</pre>
datos test)
predic_svmrad_pvalue_25 <- predict(object = svmrad_pvalue_25, newdata =</pre>
datos_test)
```

```
<- predict(object = svmrad_s2n_60, newdata =</pre>
predic_svmrad_s2n_60
datos_test)
predic_svmrad_s2n_30
                         <- predict(object = svmrad s2n 30, newdata =</pre>
datos_test)
                          <- predict(object = svmrad pca, newdata =</pre>
predic_svmrad_pca
datos_test_pca)
                          <- predict(object = rf pvalue 100, newdata =</pre>
predic_rf_pvalue_100
datos_test)
predic_rf_pvalue_50
                          <- predict(object = rf_pvalue_50, newdata =</pre>
datos test)
predic_rf_pvalue_25
                         <- predict(object = rf pvalue 25, newdata =</pre>
datos_test)
predic_rf_s2n_60
                         <- predict(object = rf_s2n_60, newdata =</pre>
datos test)
                        <- predict(object = rf_s2n_30, newdata =</pre>
predic_rf_s2n_30
datos test)
                         <- predict(object = rf_pca, newdata =</pre>
predic_rf_pca
datos_test_pca)
                         <- predict(object = nnet s2n 60, newdata =</pre>
predic_nnet_s2n_60
datos_test)
                         <- predict(object = nnet_s2n_30, newdata =</pre>
predic_nnet_s2n_30
datos_test)
predic_nnet_pvalue_100 <- predict(object = nnet_pvalue_100, newdata =</pre>
datos_test)
predic_nnet_pvalue_50
                         <- predict(object = nnet pvalue 50, newdata =</pre>
datos_test)
predic_nnet_pvalue_25
                         <- predict(object = nnet_pvalue_25, newdata =</pre>
datos_test)
predicciones <- data.frame(</pre>
      SVMrad_pvalue_100 = predic_svmrad_pvalue_100,
      SVMrad_pvalue_50 = predic_svmrad_pvalue_50,
      SVMrad pvalue 25 = predic svmrad pvalue 25,
      SVMrad_s2n_60
                         = predic svmrad s2n 60,
                         = predic_svmrad_s2n_30,
      SVMrad_s2n_30
                         = predic svmrad pca,
      SVMrad pca
      RF_pvalue_100
                         = predic_rf_pvalue_100,
      RF_pvalue_50
                         = predic_rf_pvalue_50,
      RF_pvalue_25
                         = predic_rf_pvalue_25,
      RF s2n 60
                         = predic_rf_s2n_60,
      RF_s2n_30
                         = predic_rf_s2n_30,
      RF pca
                         = predic_rf_pca,
      NNET_s2n_60
                         = predic_nnet_s2n_60,
                         = predic_nnet_s2n_30,
      NNET_s2n_30
                         = predic nnet pvalue 100,
      NNET pvalue 100
      NNET_pvalue_50
                         = predic_nnet_pvalue_50,
      NNET_pvalue_25
                         = predic_nnet_pvalue_25,
                         = datos_test$type
      valor_real
    )
```

```
predicciones %>% head()
calculo_accuracy <- function(x, y){</pre>
  return(mean(x == y))
}
accuracy test <- map dbl(.x = predicciones[, -17],
                         .f = calculo_accuracy,
                         y = predicciones[, 17]) %>%
                 as.data.frame() %>%
                 dplyr::rename(accuracy_test = ".") %>%
                 tibble::rownames to column(var = "modelo") %>%
                 arrange(desc(accuracy test))
metricas resamples %>%
  dplyr::group by(modelo, metrica) %>%
  summarise(media = mean(valor)) %>%
  spread(key = metrica, value = media) %>%
  dplyr::select(accuracy_validacion = Accuracy) %>%
  left join(accuracy test, by = "modelo") %>%
  arrange(desc(accuracy test))
metricas resamples %>%
  dplyr::group_by(modelo, metrica) %>%
  summarise(media = mean(valor)) %>%
  spread(key = metrica, value = media) %>%
  dplyr::select(accuracy_validacion = Accuracy) %>%
  left_join(accuracy_test, by = "modelo") %>%
  gather(key = "datos", value = "accuracy", -modelo) %>%
  ggplot(aes(x = reorder(modelo, accuracy), y = accuracy,
           color = datos, label = round(accuracy, 2))) +
  geom\ point(size = 9) +
  ylim(0, 1) +
  scale color_manual(values = c("orangered2", "gray50")) +
  geom_text(color = "white", size = 2.5) +
  # Accuracy basal
  geom hline(yintercept = 0.156, linetype = "dashed") +
  annotate(geom = "text", y = 0.25, x = 12, label = "Accuracy basal") +
  coord_flip() +
  labs(title = "Accuracy promedio de validación y test",
       x = "modelo") +
  theme bw() +
  theme(legend.position = "bottom")
```



Class: CIS Class: PP Class: RR Class: SP

##

##

```
## Sensitivity
                            0.6667
                                     0.00000
                                                0.8333
                                                          0.00000
                                                0.4000
## Specificity
                            0.8750
                                     1.00000
                                                         1.00000
## Pos Pred Value
                            0.6667
                                         NaN
                                                0.6250
                                                              NaN
## Neg Pred Value
                            0.8750
                                     0.90909
                                                0.6667
                                                          0.90909
## Prevalence
                            0.2727
                                     0.09091
                                                0.5455
                                                          0.09091
## Detection Rate
                            0.1818
                                     0.00000
                                                0.4545
                                                          0.00000
## Detection Prevalence
                            0.2727
                                     0.00000
                                                0.7273
                                                          0.00000
## Balanced Accuracy
                            0.7708
                                     0.50000
                                                0.6167
                                                          0.50000
```

La matriz de confusión muestra que el modelo clasifica peor unos tipos que otros.

```
confusionMatrix(data = predicciones$NNET_pvalue_50, reference =
as.factor(datos test$type))
## Confusion Matrix and Statistics
##
             Reference
##
## Prediction CIS PP RR SP
##
          CIS
                2 0
                     0 0
          PP
                0 0 1
##
                1 1 5
##
          RR
                         1
##
          SP
                0 0 0 0
##
## Overall Statistics
##
##
                  Accuracy : 0.6364
##
                    95% CI: (0.3079, 0.8907)
##
       No Information Rate: 0.5455
##
       P-Value [Acc > NIR] : 0.3853
##
##
                     Kappa: 0.3333
##
   Mcnemar's Test P-Value : NA
##
##
## Statistics by Class:
##
##
                        Class: CIS Class: PP Class: RR Class: SP
## Sensitivity
                            0.6667
                                     0.00000
                                                0.8333
                                                         0.00000
## Specificity
                                                         1.00000
                            1.0000
                                     0.90000
                                                0.4000
## Pos Pred Value
                            1.0000
                                     0.00000
                                                0.6250
                                                             NaN
## Neg Pred Value
                            0.8889
                                     0.90000
                                                0.6667
                                                         0.90909
## Prevalence
                            0.2727
                                     0.09091
                                                0.5455
                                                         0.09091
## Detection Rate
                                     0.00000
                                                0.4545
                                                         0.00000
                            0.1818
## Detection Prevalence
                            0.1818
                                     0.09091
                                                0.7273
                                                         0.00000
## Balanced Accuracy
                            0.8333
                                     0.45000
                                                0.6167
                                                         0.50000
confusionMatrix(data = predicciones$RF_pvalue_50, reference =
as.factor(datos test$type))
## Confusion Matrix and Statistics
##
```

```
##
             Reference
## Prediction CIS PP RR SP
          CIS
                1 0 1
##
          PP
                0 0 0
                         0
                2 1 5 1
##
          RR
##
          SP
                0 0 0 0
##
## Overall Statistics
##
##
                  Accuracy : 0.5455
##
                    95% CI: (0.2338, 0.8325)
##
       No Information Rate: 0.5455
##
       P-Value [Acc > NIR] : 0.6214
##
##
                     Kappa: 0.0984
##
   Mcnemar's Test P-Value : NA
##
##
## Statistics by Class:
##
##
                        Class: CIS Class: PP Class: RR Class: SP
## Sensitivity
                           0.33333
                                     0.00000
                                                 0.8333
                                                          0.00000
## Specificity
                           0.87500
                                     1.00000
                                                 0.2000
                                                          1.00000
## Pos Pred Value
                           0.50000
                                          NaN
                                                 0.5556
                                                              NaN
                                     0.90909
                                                          0.90909
## Neg Pred Value
                           0.77778
                                                0.5000
## Prevalence
                           0.27273
                                     0.09091
                                                 0.5455
                                                          0.09091
## Detection Rate
                           0.09091
                                     0.00000
                                                 0.4545
                                                          0.00000
## Detection Prevalence
                           0.18182
                                     0.00000
                                                 0.8182
                                                          0.00000
## Balanced Accuracy
                           0.60417
                                     0.50000
                                                 0.5167
                                                          0.50000
6.4.3. Mejor modelo
7. Model ensemble (stacking)
moda <- function(x, indice mejor modelo){</pre>
  tabla freq <- table(x)
  freq maxima <- max(tabla freq)</pre>
  if(sum(tabla_freq == freq_maxima) > 1) {
    # En caso de empate, se devuelve la predicción que ocupa el índice
del mejor modelo
    return(x[indice_mejor_modelo])
  return(names(which.max(table(x))))
}
predicciones ensemble <- predicciones %>%
  dplyr::select(SVMrad_pvalue_100, NNET_pvalue_100, NNET_pvalue_50,
RF_pvalue_50, RF_pvalue_25) %>%
  mutate(moda = apply(X = dplyr::select(.data =
predicciones,SVMrad_pvalue_100, NNET_pvalue_100, NNET_pvalue_50,
RF pvalue 50, RF pvalue 25),
```

```
MARGIN = 1,
                      FUN = moda,
                      indice_mejor_modelo = 1))
predicciones ensemble %>% head()
mean(predicciones_ensemble$moda == datos_test$type)
## [1] 0.6363636
8. Clustering
library(factoextra)
# Se unen de nuevo todos los datos en un único dataframe
datos clustering <- bind rows(datos train, datos test)</pre>
datos_clustering <- datos_clustering %>% arrange(type)
# La librería factoextra emplea el nombre de las filas del dataframe para
identificar cada observación.
datos_clustering <- datos_clustering %>% as.data.frame()
rownames(datos_clustering) <- paste(1:nrow(datos_clustering),</pre>
datos_clustering$type, sep = "_")
# Se emplean únicamente los genes filtrados
datos clustering <- datos clustering %>% dplyr::select(type,
filtrado_anova_pvalue_100)
# Se calculan las distancias en base a la correlación de Pearson
mat_distancias <- get_dist(datos_clustering[, -1],</pre>
                           method = "pearson",
                           stand = FALSE)
library(cluster)
# HIERARCHICAL CLUSTERING
set.seed(101)
hc average <- hclust(d = mat distancias, method = "complete")</pre>
# VISUALIZACIÓN DEL DENDOGRAMA
# Vector de colores para cada observacion: Se juntan dos paletas para
tener
# suficientes colores
library(RColorBrewer)
colores <- c(brewer.pal(n = 8, name = "Dark2"),
             brewer.pal(n = 8, name = "Set1")) %>%
          unique()
# Se seleccionan 6 colores, uno para cada tipo
colores <- colores[1:6]</pre>
```

```
# Se asigna a cada tipo de tumor uno de los colores. Para conseguirlo de
# rápida, se convierte la variable tipo_tumor en factor y se emplea su
codificación
# numérica interna para asignar los colores.
colores <- colores[as.factor(datos_clustering$type)]</pre>
# Se reorganiza el vector de colores según el orden en que se han
agrupado las
# observaciones en el clustering
colores <- colores[hc_average$order]</pre>
fviz_dend(x = hc_average,
          label_cols = colores,
          cex = 0.2,
          1wd = 0.1,
          main = "Linkage completo",
          type = "circular")
                  -1.0
                   -0.5
                   0.0
                   0.5
                   10
```

Actualización del cronograma.

La nueva planificación queda así:

Tarea	Inicio	Fin	Dificultad
PECO. PROPUESTA TFM	2021- 02-17	2021- 03-01	7
PEC1. PLAN DE TRABAJO	2021-	2021- 03-16	7
Estudio y selección de datos que contengan muestras de diferentes fases de EM	03-02 2021- 03-17	2021- 04-10	6
Selección de algoritmos clasificadores y paquetes	2021-	2021-	5

en R	03-17	04-10	
Reestructuración de los datos	2021- 04-10	2021- 04-15	6
Entreno y evaluación clasificadores	2021- 04-15	2021- 04-19	8
ENTREGA PEC2	2021- 04-19	2021- 04-19	NA
Selección y reestructuración de nuevos datos	2021- 04-20	2021- 05-02	9
División y preprocesado	2021- 05-03	2021- 05-06	6
Filtrado de genes	2021- 05-07	2021- 05-09	8
Aplicación de los algoritmos y comparación de modelos	2021- 05-09	2021- 05-17	8
ENTREGA PEC3	2021- 05-17	2021- 05-17	NA
Cambio de clases	2021- 05-18	2021- 05-21	5
Filtrado de genes, entreno y evaluación	2021- 05-22	2021- 06-05	6
Conclusiones	2021- 06-05	2021- 06-08	8
Redacción dela Memoria	2021- 06-01	2021- 06-08	7
ENTREGA PEC4	2021- 06-08	2021- 06-08	NA
PEC5a. Elaboración de la presentación	2021- 06-9	2021- 06-13	NA
PEC5b. Defensa pública	2021- 06-16	2021- 06-23	NA

